



TRABAJO FIN DE GRADO
INGENIERÍA EN INFORMÁTICA

Predicción de Decisiones Basada en Actividad Cerebral Previa en Dispositivos Wearables

Autor

Ismael Tengo Rodríguez

Directores

Ana Álvarez Muelas

Francisco Manuel García Moreno



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE
TELECOMUNICACIÓN

Granada, noviembre de 2024

Predicción de Decisiones Basada en Actividad Cerebral Previa en Dispositivos Wearables

Ismael Tengo Rodríguez

Palabras claves: EEG, electroencefalograma, aprendizaje automático, predicción decisiones, actividad cerebral, dispositivo wearable, clasificación binaria, extracción de características, selección de características.

Resumen

A lo largo de este trabajo se explora la posibilidad de realizar una predicción binaria intrasujeto basada en los datos de la actividad cerebral.

Partiendo de un conjunto de datos extraído con un dispositivo wearable Muse S, utilizando el protocolo experimental propuesto en la investigación de Soon, et al. (2008) [1], se realizará un procesamiento de datos enfocado en la extracción de ventanas de datos centradas en los momentos cruciales del experimento. Sobre estas ventanas realizaremos una extracción de características con tsfresh y su correspondiente selección de características relevantes.

Finalmente entrenaremos 3 modelos, Random Forest, Support Vector Machine y XGBoost. Los resultados obtenidos oscilan entorno al 75 % de accuracy, la investigación de Soon obtiene una tasa de acierto del 60 %.

Predicting Decisions Based on Previous Brain Activity on Wearable Devices

Ismael Tengo Rodríguez

Palabras clave: EEG, electroencephalogram, machine learning, decision prediction, brain activity, wearable device, binary classification, feature extraction, feature selection.

Resumen

This paper explores the possibility of binary intrasubject prediction based on brain activity data.

Starting from a dataset extracted with a Muse S wearable device, using the experimental protocol proposed in the research of Soon, et al. (2008), a data processing focused on the extraction of data windows centred on the crucial moments of the experiment will be performed. On these windows we will perform a feature extraction with tsfresh and its corresponding selection of relevant features.

Finally, we will train 3 models, Random Forest, Support Vector Machine and XGBoost. The results obtained fluctuate around 75 % accuracy, Soon's research obtains a hit rate of 60 %.

Yo, **Ismael Tengo Rodríguez**, alumno de la titulación Ingeniería Informática de la **Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación de la Universidad de Granada**, con DNI , autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Grado en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

Fdo: Ismael Tengo Rodríguez

Granada a 12 de noviembre de 2024.

D. **Ana Álvarez Muelas**, Profesora del Departamento de Personalidad, Evaluación y Tratamiento Psicológico de la Universidad de Granada.

D. **Francisco Manuel García Moreno**, Profesor del Departamento de Lenguajes y Sistemas Informáticos de la Universidad de Granada.

Informan:

Que el presente trabajo, titulado ***Predicción de Decisiones Basada en Actividad Cerebral Previa en Dispositivos Wearables***, ha sido realizado bajo su supervisión por **Ismael Tengo Rodríguez**, y autorizamos la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expiden y firman el presente informe en Granada a 12 de noviembre de 2024.

Los directores:

Ana Álvarez Muelas **Francisco Manuel García Moreno**

Agradecimientos

Agradezco enormemente a mi familia por apoyarme a lo largo de toda mi carrera académica y a los amigos que he hecho en la universidad a lo largo de este año, que han hecho más ameno el camino, especial mención a las famosas 'noches de durum'.

Índice general

| | |
|---|-----------|
| 1. Introducción | 1 |
| 2. Fundamentos teóricos | 2 |
| 3. Estado del arte | 15 |
| 4. Materiales y métodos | 19 |
| 4.1. Datos | 19 |
| 4.2. Planificación | 24 |
| 4.3. Tecnologías utilizadas | 25 |
| 4.4. Costes | 26 |
| 5. Experimentos | 28 |
| 5.1. Preprocesamiento | 28 |
| 5.2. Extracción de características | 30 |
| 6. Conclusiones | 38 |
| A. Estadísticas de datos para cada tamaño de ventana | 40 |
| Bibliografía | 50 |

Índice de figuras

| | | |
|------|---|----|
| 2.1. | Relación entre los términos del dominio del tiempo y de la frecuencia utilizados para realizar la transformada de Fourier sobre una señal digital. Fuente: [11] | 4 |
| 2.2. | <i>An intuitive explanation of the trade-off between time and frequency resolution in STFT. (a) and (b) show a nonstationary time-series signal $x(n)$ and two analyzing windows (Window 1 and Window 2) of different lengths. Window 2 has shorter length compared to Window 1. (c) shows that high frequency and low time resolution is achieved if long window (Window 1) is used to analyze the signal. (d) shows that good time resolution and poor frequency resolution is obtained if window of shorter length (Window 2) is used to analyze the signal. Fuente: [13]</i> | 6 |
| 2.3. | Guía para elegir el método de selección de características. Fuente: [20] | 8 |
| 2.4. | Definición del margen entre clases en SVM [39]. | 11 |
| 2.5. | Matriz de confusión Fuente: https://www.ml-science.com/confusion-matrix | 12 |
| 3.1. | Diseño del experimento. | 17 |
| 4.1. | Sistema internacional 10-10 Fuente: https://naxonlabs.com/blog/understanding-strategic-placement-sensors-eeg-devices | 21 |
| 4.2. | Imagen de (a) dispositivo EEG (Muse), que consta de cuatro electrodos (AF7, AF8, TP9 y TP10), y (b) distribución EEG de electrodos basada en el posicionamiento internacional 10/20. Fuente: https://www.medrxiv.org/content/10.1101/2024.04.19.24306029v1.full | 21 |
| 4.3. | Dispositivo wearable utilizado para la obtención de los datos del EEG. Fuente: https://choosemuse.com/products/muse-s-gen-2 | 23 |
| 4.4. | Pasos de un proyecto de ML | 24 |
| 4.5. | Diagrama de Gantt con la planificación temporal del proyecto. | 25 |
| 5.1. | Frecuencias presentes en el archivo 1 | 30 |

| | |
|--|----|
| 5.2. Frecuencias presentes en la primera ventana (1 segundo) de datos del fichero 1. | 31 |
| 5.3. Frecuencias presentes en la primera ventana (1 segundo) de datos del fichero 1 tras el filtro de 50Hz. | 32 |
| 5.4. Datos de la ventana de 1 segundo. | 33 |
| 5.5. Datos de la ventana de 1 segundo tras el filtro de 50Hz. . . . | 34 |
| 5.6. G-Mean en todos los sujetos y ventanas. | 34 |

Índice de cuadros

| | |
|--|----|
| 4.1. Costes hardware | 26 |
| 4.2. Coste final del proyecto | 27 |
| 5.1. Resultados para las ventanas de 1 segundo. | 35 |
| 5.2. Resultados para las ventanas de 2,5 segundos. | 35 |
| 5.3. Resultados para las ventanas de 5 segundos. | 36 |
| 5.4. Resultados para las ventanas de 7,5 segundos. | 36 |
| 5.5. Resultados para las ventanas de 10 segundos. | 37 |
| 5.6. Resumen (media y desviación típica) de los distintos tamaños de ventana. | 37 |
| A.1. Balance de clases para las ventanas de 1 segundo. | 41 |
| A.2. Balance de clases para las ventanas de 2,5 segundos. | 41 |
| A.3. Balance de clases para las ventanas de 5 segundos. | 42 |
| A.4. Balance de clases para las ventanas de 10 y 7,5 segundos. | 42 |

Capítulo 1

Introducción

Existe un interés en explorar cómo de conscientes somos (libre albedrío) cuando tomamos decisiones en la vida cotidiana. La actividad cerebral previa a un estímulo puede ofrecer pistas sobre la predisposición o inclinación hacia ciertas decisiones. En este proyecto, se propone investigar si es posible predecir la elección de un participante basándose en su actividad cerebral justo antes de una toma de decisión binaria, como podría ser el caso de decidir entre pulsar el botón izquierdo o el derecho.

Una gran cantidad de proyectos de investigación en neurociencia están basados o bien en la toma de datos de electroencefalogramas (EEG) o en imágenes por resonancia magnética funcional (fMRI). El enfoque del análisis de este trabajo se centra en los datos EEG disponibles en el intervalo de tiempo inmediatamente anterior a la toma de decisión, basado en la toma de datos del protocolo experimental de Soon[1]. Utilizando técnicas avanzadas de Machine Learning, se busca identificar patrones o características específicas en estos datos que puedan indicar una predisposición hacia una elección particular. Por ejemplo, podría ser que ciertos patrones de actividad cerebral sugieran que un participante está más inclinado a pulsar la tecla izquierda en lugar de la derecha, incluso antes de que se presente el estímulo visual.

Encontrar una correlación significativa, podría tener implicaciones profundas para nuestra comprensión del libre albedrío y cómo nuestras decisiones pueden estar influenciadas por procesos cerebrales subconscientes.

Capítulo 2

Fundamentos teóricos

Antes de empezar necesitamos tener una idea de los conceptos básicos con los que vamos a trabajar.

Dispositivos wearables Son accesorios ligeros basados en sensores, que permiten detectar, analizar y transmitir información de diversos ámbitos [2]. Los más conocidos son los relojes inteligentes pero en este trabajo se ha utilizado un dispositivo "Muse S", se trata de una diadema que permite monitorizar la actividad cerebral en tiempo real. Este dispositivo podría ser clasificado como parte de una **BCI**, Brain-Computer Interface

BCI Sistema capaz de medir la actividad cerebral, procesarla para obtener características de interés e interaccionar con el entorno de la forma deseada por el usuario.[3]

Actividad cerebral Se trata del fenómeno eléctrico y químico, producido por la actividad funcional de las neuronas en el cerebro. Cada pensamiento, sensación o movimiento que sentimos se traduce en patrones específicos de actividad eléctrica y química. Este trabajo se centrará en analizar las señales eléctricas(ondas) mediante técnicas de aprendizaje automático. Dichas señales eléctricas son del orden de los microvoltios [4]. La actividad de una neurona es demasiado pequeña por lo que los electrodos obtiene los datos de la suma de una gran cantidad de neuronas.

Estímulo En psicología se define como cualquier incentivo, información o señal que provoca una respuesta en el individuo [5].

Libre albedrío El libre albedrío es la capacidad de los seres humanos de tomar decisiones autónomas, o sea, de elegir entre varias alternativas. Esto implica asumir la responsabilidad de las propias acciones [6].

EEG Un electroencefalograma, EEG, es el registro de las fluctuaciones eléctricas en el cerebro para obtener dicho registro se realiza una electroencefalografía que es una técnica de exploración funcional mediante la cual se obtiene dicho registro. Actualmente el término EEG se usa tanto para referirse al procedimiento como al resultado.

Teoría de ondas Es conveniente conocer los fundamentos de las ondas debido a que trabajaremos con señales eléctricas, dichas señales serán tomadas por el dispositivo wearable y aparecerán en el EEG. Estas señales se pueden descomponer en las diferentes frecuencias que la componen, de la misma manera que un sonido o una imagen.

Onda Una onda es la propagación de una fluctuación o perturbación en alguna propiedad del espacio, como el campo eléctrico, implicando un transporte de energía sin transporte de materia [7].

Señal Una señal es una función que transmite información sobre el comportamiento o los atributos de un fenómeno [8].

Componentes de las ondas

Frecuencia Describe cuantas ondas completas hay en un segundo, es el número de repeticiones por unidad de tiempo de cualquier proceso periódico.

Amplitud Se refiere al tamaño de la onda, es decir, la distancia máxima entre el punto medio de la onda y el punto más alejado. Según el campo de la ciencia, la amplitud se mide en distintas unidades, en caso del potencial eléctrico se utilizan los voltios.

Existen más características de las ondas pero principalmente nos interesan estas dos para este trabajo.

Ondas cerebrales Para la realización de este trabajo se definen las siguientes ondas cerebrales [9]:

Delta Entre 0.2 y 4Hz aparecen principalmente cuando estamos dormidos.

Theta Entre 4 y 8Hz representan un estado de relajación profunda o meditación.

Alpha Entre 8 y 12Hz, reflejan un estado de relajado.

Beta Entre 12 y 30Hz se sitúan los momentos de atención y trabajo.

Gamma Por encima de 30Hz se representan las situaciones de gran concentración, ansiedad o pánico.

Transforma de Fourier Cuando trabajamos con señales digitales normalmente los datos son registrados en el dominio del tiempo, esto significa que cada cierto intervalo de tiempo, determinado

por la tasa de muestreo, 'sampling rate', se tomará un dato del valor de la señal. La transformada de Fourier nos permite pasar del dominio del tiempo al dominio de la frecuencia, es decir descompone una señal en 'todas' sus frecuencias y podemos ver el valor de la señal, la amplitud, para cada una de estas frecuencias. A esta descomposición se le conoce como 'espectro', este se define como una representación gráfica que muestra la variación de su módulo o de su fase respecto a la frecuencia.” [10]. Esto es bastante útil pero tiene un inconveniente y es que perdemos la resolución temporal, a no ser que realicemos dicha transformada en ciertos trozos de toda la señal, a estos trozos los llamaremos ventanas.

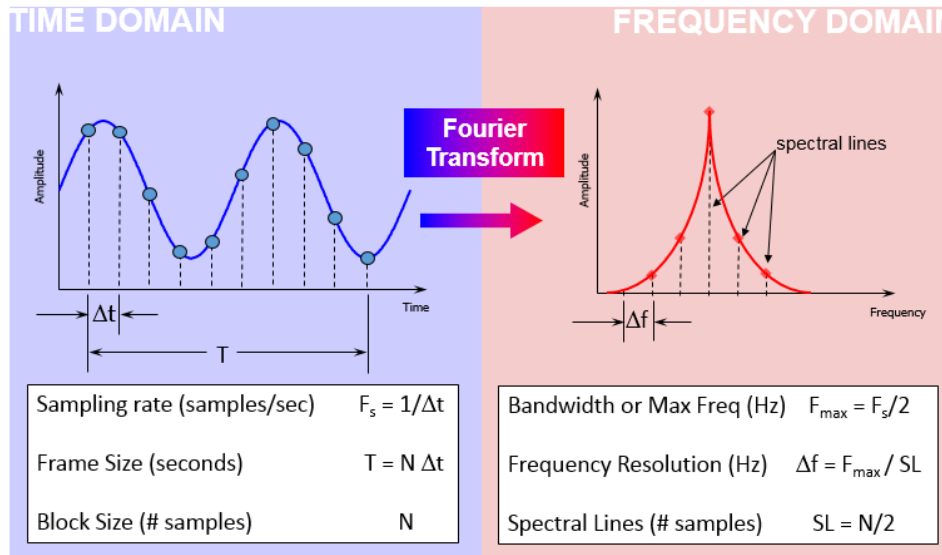


Figura 2.1: Relación entre los términos del dominio del tiempo y de la frecuencia utilizados para realizar la transformada de Fourier sobre una señal digital. Fuente: [11]

Para calcular la Transformada de Fourier utilizaremos la fórmula discreta dado que lo que tenemos son las muestras de la actividad cerebral, que realmente es una señal continua. ^{1 2}

$$\hat{g}(f) = \sum_{k=1}^N g(t_k) e^{-2\pi i f t_k} \quad (2.1)$$

¹Excelente explicación de la Transformada de Fourier <https://www.3blue1brown.com/lessons/fourier-transforms>

²Notas sobre el escalado de la Transformada de Fourier https://appliedacousticschalmers.github.io/scaling-of-the-dft/AES2020_eBrief/

La frecuencia más alta que se puede determinar es igual a la mitad del valor de la tasa de muestreo, esto es consecuencia del Teorema de muestreo de Nyquist-Shannon [12], que establece que si una señal(función) no presenta ninguna frecuencia mayor que B , entonces puede ser muestreada sin pérdida de información con una tasa de muestreo $\geq 2B$.

También existe cierta analogía con el principio de incertidumbre de Heisenberg que establece que no se puede determinar la posición y la velocidad de una partícula con precisión arbitraria, esto de la precisión arbitraria se refiere a una precisión muy grande o 'infinita', que está limitada solo por la memoria del sistema. En cuanto a la analogía, en el análisis de señales existe el balance 'trade-off' entre resolución temporal y de frecuencia, donde si queremos una buena resolución en el dominio temporal necesitamos ventanas de datos pequeñas y si queremos una alta resolución en frecuencia necesitamos ventanas grandes de cara a aplicar la transformada sobre dichas ventanas. Podemos ver un ejemplo en la [Figura 2.2](#).

Este es uno de la de las principales problemas del análisis de frecuencias mediante la Transformada de Fourier. Esto nos incita a buscar otros procedimientos similares que resuelvan estas limitaciones, como la STFT, short-time Fourier Transform, o los wavelets [14].

A pesar de las limitaciones que tiene la Transformada de Fourier es una excelente herramienta en el análisis de señales y tiene un gran cantidad de usos en muchos campos de la ciencia, desde la música hasta la química.

Inteligencia Artificial Es un conjunto de tecnologías que permiten que las computadoras realicen una variedad de funciones avanzadas, incluida la capacidad de ver, comprender y traducir lenguaje hablado y escrito, analizar datos, hacer recomendaciones y mucho más [15].

La inteligencia artificial es un campo de la ciencia relacionado con la creación de computadoras y máquinas que pueden razonar, aprender y actuar de una manera que normalmente requeriría inteligencia humana o que involucra datos cuya escala excede lo que los humanos pueden analizar.

La IA es un campo amplio que incluye muchas disciplinas, como la informática, el análisis y la estadística de datos, la ingeniería de hard-

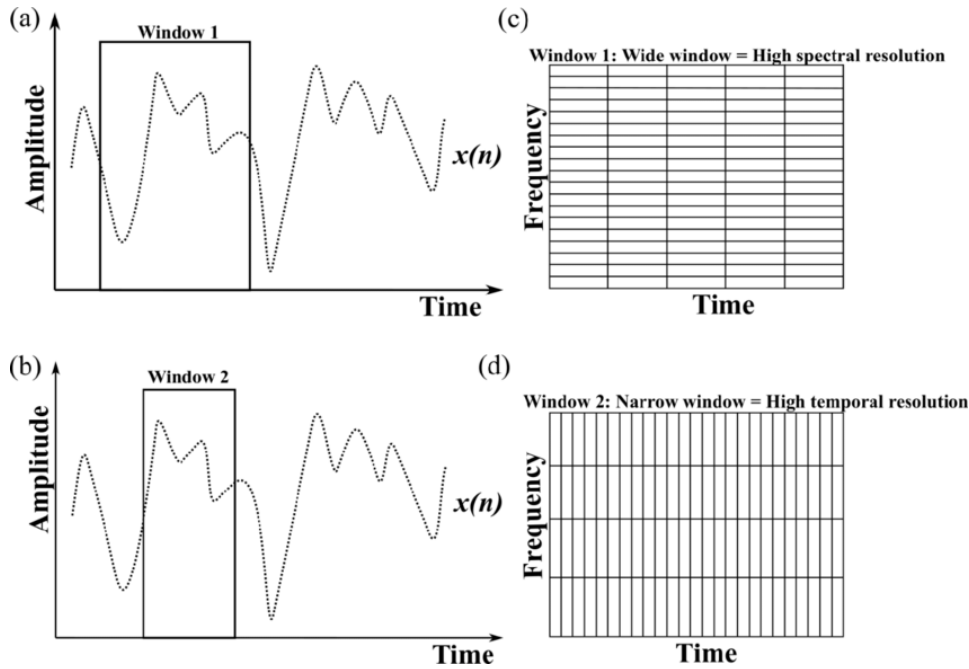


Figura 2.2: An intuitive explanation of the trade-off between time and frequency resolution in STFT. (a) and (b) show a nonstationary time-series signal $x(n)$ and two analyzing windows (Window 1 and Window 2) of different lengths. Window 2 has shorter length compared to Window 1. (c) shows that high frequency and low time resolution is achieved if long window (Window 1) is used to analyze the signal. (d) shows that good time resolution and poor frequency resolution is obtained if window of shorter length (Window 2) is used to analyze the signal. Fuente: [13]

ware y software, la lingüística, la neurociencia y hasta la filosofía y la psicología.

Machine Learning Traducido al español como aprendizaje automático, es un subconjunto de la inteligencia artificial que permite que un sistema aprenda y mejore de forma autónoma con redes neuronales y aprendizaje profundo, sin necesidad de una programación explícita, a través del análisis de grandes cantidades de datos.

El aprendizaje automático permite que los sistemas informáticos se ajusten y mejoren continuamente a medida que acumulan más 'experiencia'. Por lo tanto, el rendimiento de estos sistemas puede mejorar si se proporcionan conjuntos de datos más grandes y variados para su procesamiento [16].

Extracción de características Es un proceso del aprendizaje automático en el que se identifican y extraen características relevantes de los datos, con el objetivo de realizar posteriormente tareas de clasificación, regresión o agrupación [17].

En este trabajo hicimos uso de una herramienta automática de extracción de características, conocida como tsfresh [18][19]. Es un paquete de Python que calcula una gran cantidad de variables relacionadas con series temporales

Selección de características Tras la extracción de características, realizamos una selección, es decir, reducimos el número de variables que vamos a utilizar para el desarrollo de nuestro modelo[20].

Es importante realizar esta selección de cara a reducir el coste computacional de nuestro modelo y en algunos casos mejorar su rendimiento.

Existen dos formas generales de realizar selección de características, de forma supervisada o no supervisada. La diferencia radica en si las variables seleccionadas se eligen en función de su relación con la variable objetivo o no. En la selección no supervisada, no tendremos en cuenta la variable objetivo, este tipo de selección se centra en eliminar características redundantes y se basa en la correlación de las variables. En cambio la selección supervisada se basa en la relación existente entre las características(features) y variable objetivo (target) con el objetivo de eliminar los atributos irrelevantes.

La selección supervisada se suele dividir en otras dos principales técnicas, 'wrapper' y 'filter'. Wrapper se basa en la creación de muchos modelos con diferentes subconjuntos de características, es un método computacionalmente costoso. Por otro lado filter se basa en técnicas estadísticas donde se evalúa la relación entre una feature y el target, de esta manera podremos seleccionar las características más relacionadas con nuestro objetivo.

También existen otras técnicas que realizan la selección de características como parte del entrenamiento del modelo, a esta método se le conoce como selección de característica intrínseca.

En relación con este tema podemos hablar también sobre la reduc-




Figura 2.3: Guía para elegir el método de selección de características. Fuente: [20]

ción de dimensionalidad, que también busca disminuir el número de variables, pero a diferencia de la selección de características, donde utilizamos un subconjunto de las características iniciales, en la reducción de dimensionalidad se crea una proyección de los datos obteniendo un nuevo conjunto de características, por ejemplo PCA [21].

Volviendo a las técnicas estadísticas, estas suelen realizarse teniendo en cuenta únicamente una sola feature y el target en cada etapa, a esta forma de evaluar la relación se le conoce como análisis univariable [22].

En función del tipo de datos con el que estemos trabajando tendremos que elegir un método de selección u otro, podemos ver una guía de selección en la Figura 2.3 .

Estos test se basan en la significancia estadística es decir, evalúan si un resultado se ha producido al azar o si por el contrario, es significativo. La significancia estadística se relaciona con la necesidad de probar una hipótesis, para ello se harán uso de las pruebas de hipótesis, que permiten cuantificar hasta que punto la variabilidad de la muestra es significativa en los resultados. Se establece una hipótesis nula H_0 que representa la afirmación de que no existe relación entre ambas variables y por otro lado, la hipótesis alternativa H_1 que afirma que si existe relación entre las variables [23] [24]. Para decidir que hipótesis elegir, primero establecemos un valor de confianza, normalmente 95 %, o alternativamente un nivel de significancia 5 %, representado habitualmente como α [25], calculamos el p-valor, si el resultado es menor que α , 0.05, entonces rechazamos la hipótesis nula, aceptando la hipótesis alternativa, es decir representar con un 95 % de seguridad que la variable es significativa.

Cuando hablábamos de los tipos de selección de características, comentábamos que un tipo se centraba en eliminar característica redundantes y el otro buscaba las características más relevantes, una técnica que realiza ambas funciones es Minimum Redundancy Maximum Relevance, mRMR, en español, Mínima Redundancia Máxima Relevancia [26][27][28].

Modelos Los modelos son programas que han sido entrenados a partir de un conjunto de datos, con el objetivo de identificar patrones y ser capaces de realizar predicciones, para ello aplican diferentes algoritmos con un mismo objetivo, alcanzar el resultado esperado y realizar correcciones a partir del error obtenido [29]. Para el desarrollo de este trabajo se han utilizado los siguientes algoritmos:

Random Forest Se trata de un algoritmo bastante utilizado en aprendizaje automático para problemas de clasificación como de regresión. Se basa en la combinación de la salida de múltiples árboles de decisión con el objetivo de alcanzar un único resultado final.

Los árboles de decisión utilizan sus nodos para dividir los datos. Cada nodo es una regla binaria sobre los datos de entrada, por ejemplo, si trabajásemos sobre los días de la semana un nodo podría preguntar si el día a predecir es fin de semana obteniendo una subdivisión de los datos en dos grupos, uno de 5 días (L-V) y otro de 2 (S-D). Cada uno de estos nodos permitirá avanzar hasta llegar a los nodos hoja donde se determinará la respuesta final.

Los árboles de decisión son entrenados mediante el algoritmo CART [30], Classification and Regression Tree, y pueden utilizar diversas métrica para evaluar la calidad de la división de datos de cada nodo, tales como, la impureza Gini [31], la ganancia de información [32](Divergencia de Kullback-Leibler) o el error cuadrático medio [33] (MSE por sus siglas en inglés).

En Random Forest, cada uno de los árboles de decisión se entrena con una muestra ligeramente diferente de los datos de entrenamiento, generada mediante bootstrapping, finalmente una nueva predicción se calcula como la agregación de las predicciones de todos los árboles de decisión.

El bagging [34] o bootstrapping [35] es una técnica estadística que permite estimar el sesgo y varianza de un estimador utilizando un muestreo con reemplazo de los datos de entrenamiento.

Los árboles de decisión son fácilmente interpretables, aunque tienden a sobreajustarse a los datos por lo que podemos encontrar problemas de generalización. También son inestables por lo que modificar el conjunto de datos puede dar lugar a grandes cambios en la estructura del modelo.

Podemos definir su complejidad algorítmica en base a los siguientes parámetros [36]:

n Número de casos de entrenamiento.

f Número de características.

k N° de árboles

p N° de nodos en el árbol

d Profundidad del árbol

Finalmente podemos definir la complejidad de la siguiente manera:

- Complejidad en tiempo de entrenamiento: $O(n \cdot \log(n) \cdot f \cdot k)$
- Complejidad en tiempo para inferencia: $O(d \cdot k)$
- Complejidad en espacio inferencia: $O(p \cdot k)$

Xgboost Extreme Gradient Boosting [37] [38], es utilizado en problemas de aprendizaje supervisado, está basado en la combinación de árboles de decisión entrenados de forma secuencial, a diferencia de random forest, donde se pueden entrenar los árboles en paralelo, en este caso se realiza de esta manera debido a que cada árbol intenta mejorar los errores de los árboles anteriores, esto podría generar un sobreajuste por lo que de la misma manera que en RF, la predicción de una nueva observación se obtiene como la agregación de todos los árboles individuales que forman el modelo.

A esta técnica de entrenamiento secuencial se le conoce como boosting.

SVM Support Vector Machine es un algoritmo de aprendizaje supervisado utilizado en problemas de clasificación y regresión [39].

El algoritmo SVM busca el hiperplano que separe de la mejor forma posible los puntos pertenecientes a dos clases (aunque puede extenderse el algoritmo para problemas multiclases), es decir con el margen más amplio entre las dos clases. Cuando hablamos del margen, [Figura 2.4](#), nos referimos a la anchura existente entre en la región paralela al hiperplano que no tiene puntos de datos interiores. Este plano solo se puede encontrar en problemas linealmente separables, esto no ocurre siempre, por lo que para lidiar con estos casos el algoritmo es flexible con algunas clasificaciones erróneas.




Figura 2.4: Definición del margen entre clases en SVM [\[39\]](#).

Podemos definir su complejidad algorítmica en base a los siguientes parámetros [\[36\]](#):

- n** Número de casos de entrenamiento.
- f** N^o de características.
- s** N^o de vectores de soporte.

Cabe destacar que la complejidad de SVM varía en función del kernel usado.

Finalmente podemos definir la complejidad de la siguiente manera:

- Complejidad en tiempo de entrenamiento: Entre $O(n^2)$ y $O(n^3)$.
- Complejidad en tiempo para inferencia: $O(s)$ para el kernel lineal y $O(s*f)$ para el kernel RBF y polinómico.
- Complejidad en espacio para inferencia: $O(s)$.

Cuenta con los siguientes parámetros:

- C: Parámetro de regularización que controla el margen del SVM. Valores más altos de C dan menos tolerancia a errores de clasificación, mientras que valores bajos permiten más errores para tener un margen más amplio.

- kernel: El tipo de función kernel que utiliza el modelo. Algunas opciones comunes son:

linear: Kernel lineal.

poly: Kernel polinomial.

rbf: Kernel de base radial (el más utilizado).

sigmoid: Kernel sigmoide.

- gamma: Coeficiente para los kernels no lineales (como rbf, poly y sigmoid). Controla el grado de influencia de cada muestra de entrenamiento.

'scale': Valor por defecto, usa $(1/(n_features * var(X)))$.

'auto': Usa $(1/n_features)$.

Métricas Las métricas son medidas cuantitativas que permiten medir el rendimiento de un modelo. Existen una gran variedad de métricas, la elección de estas dependerá del problema que estemos resolviendo, ya que cada una evalúa un aspecto distinto. Dado que nos encontramos ante un problema de clasificación, nos basaremos principalmente en la matriz de confusión para calcular las métricas.

La matriz de confusión es una tabla que compara las predicciones del modelo con los valores reales, [Figura 2.5](#).

| | | Actual Class | |
|-----------------|--------------|---------------------|---------------------|
| | | Positive (P) | Negative (N) |
| Predicted Class | Positive (P) | True Positive (TP) | False Positive (FP) |
| | Negative (N) | False Negative (FN) | True Negative (TN) |

Figura 2.5: Matriz de confusión Fuente: <https://www.ml-science.com/confusion-matrix>

A partir de esta tabla se calculan las siguientes métricas básicas que se utilizarán para calcular métricas más útiles.

Verdaderos positivos (TP) Son los ejemplos correctamente predichos como positivos.

Verdaderos negativos (TN) Son los ejemplos correctamente predichos como negativos.

Falsos positivos (FP) Son los ejemplos incorrectamente predichos como positivos, también conocidos como error de tipo 1.

Falsos negativos (FN) Son los ejemplos incorrectamente predichos como negativos, también conocidos como error de tipo 2.

En base a estas métricas calcularemos las que finalmente vamos a utilizar [40][41].

Accuracy (acc) Mide la proporción de predicciones correctas sobre el número de predicciones totales, suele ser la métrica más usada, pero tiene algunos inconvenientes ya que por ejemplo no tiene en cuenta si las clases están desbalanceadas.

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

Precision (p) Proporción de verdaderos positivos frente a todas las predicciones positivas.

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

Sensitivity ó Recall (r) Mide la capacidad de detectar los casos positivos, es especialmente útil si queremos evitar falsos negativos

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Specificity (sp) Proporción de verdaderos negativos frente a todos los casos negativos.

$$\text{Specificity} = \frac{\text{TN}}{\text{TN} + \text{FP}}$$

Accuracy Balanced Accuracy para clases desbalanceadas.

$$\text{Balanced Accuracy} = \frac{1}{C} \sum_{i=1}^C \frac{\text{TP}_i}{\text{TP}_i + \text{FN}_i}$$

La fórmula anterior es para el caso general con 'C' clases, nosotros solo trabajaremos con dos.

F1-Score Media armónica entre recall y precision, es útil cuando se quiere encontrar un equilibrio entre las dos métricas, por ejemplo en problemas con clases desbalanceadas.

$$\text{F1-Score} = \frac{2 * p * r}{p + r}$$

G-mean Mide el equilibrio entre el rendimiento de clasificación de ambas clases.

$$\text{G-Mean} = \sqrt{\text{Recall} \times \text{Specificity}}$$

Capítulo 3

Estado del arte

El acto de tomar decisiones conlleva analizar información y llegar a una conclusión, es una tarea fundamental para los humanos, es por eso que existe un gran interés en entender los mecanismos que nos hacen tomar decisiones [42]. En la literatura existen diversos paradigmas para simular y estudiar la toma de decisiones tales como los juegos de azar, Delay Discounting Task, DDT [43] y Ultimatum Game, UG [44]. Cada uno de estos paradigmas se suele usar para evaluar distintos aspectos de la toma de decisiones como la contabilidad económica, impulsividad, toma de decisiones a largo plazo, la justicia o los procesos de negociación .

En este trabajo fin de grado se utilizó un paradigma distinto, que se ha ido refinando a partir de diversas investigaciones [45][1][46]. En la primera investigación mencionada, realizada por Libet en 1983 [45], el paradigma de decisión consistía en realizar un movimiento de muñeca o dedo en el momento en el que el sujeto sintiese la necesidad de realizarlo, mientras tanto, su actividad cerebral era medida.

Para situar en el tiempo el momento del instante de la necesidad de moverse Libet[45] empleó el conocido ahora como el 'intention clock'[46], se trata de un reloj en el cual los participantes tenían que fijarse en la posición de la manecilla del reloj en el momento ser conscientes de la necesidad de tomar una decisión (instante denotado como 'W' de 'wanting'), consiguiendo así asociar un instante de tiempo con la decisión de moverse, de este modo y basandose en el 'readiness potential' (RP, traducido como potencial de preparación, originalmente en alemán como 'bereitschaftspotential', (BP)), es una medida de actividad cerebral en la corteza motora, que conduce al movimiento muscular voluntario o simplemente a la anticipación de una acción, Libet llevó a cabo su investigación.

Libet pedía a los participantes que no parpadeasen una vez iniciado un ciclo de reloj, hasta que no pulsasen uno de los dos botones libremente, debido a que los parpadeos pueden introducir artefactos (ruido que aparece

en el EEG por motivos el movimientos de los músculos, ojos, latidos del corazón e incluso la corriente eléctrica de los cables), si parpadeaban tenían que esperar al siguiente ciclo.

Finalmente Libet tras analizar los resultados de 6 sujetos diestros, concluye que, la toma de decisiones se realizaba de forma inconsciente y que unos milisegundos más tarde, las personas eran conscientes de que ellos habían tomado una decisión, cuando en realidad todo había ocurrido en su subconsciente. Esta conclusión se basa en que los participantes señalaban el instante de decisión unos 200 milisegundos antes de la realización del movimiento, y el RP comenzaba a registrarse 350ms antes del instante de decisión, las decisiones se toman en el cerebro de manera inconsciente hasta 350ms antes de que los sujetos fuesen conscientes de la decisión.

Algunas investigaciones no llegaron a los mismos resultados [47], declararon que el experimento no era lo suficientemente preciso como para sacar conclusiones, algunos de los problemas que exponían eran los siguientes. La condición de fijarse en el reloj podría interferir con la espontaneidad de la toma de decisión. Otro problema que se presenta, es la baja resolución espacial de las señales del EEG. Para vincular la actividad cerebral con una decisión (izquierda o derecha), sería conveniente poder distinguir las señales entre dichas opciones. En 1999 Haggard y Eimer [48], realizaron una variación del experimento donde los sujetos también tenían que elegir que mano mover, en su investigación fueron capaces de utilizar 'Lateralized Readiness Potential' (LRP), un tipo de RP que permitía discernir la actividad cerebral de una decisión motora (movimiento de una mano) frente a la actividad general como los cambios en la excitación [46], para conseguir esto se media la diferencia de potencial entre el hemisferio derecho y el izquierdo, concluyeron que en lugar de tener en cuenta el RP, que era un indicador general del movimiento, debía tenerse en cuenta el LRP, como un indicador más específico del movimiento realizado.

Los investigadores Jeff Miller y Judy Trevena en 2010 [49] señalan que el RP no es más que una señal de que el cerebro está prestando atención. Para llegar a esta conclusión realizaron una modificación del experimento de Libet donde utilizaban un sonido para indicar a los voluntarios si debían pulsar un botón o no, los resultados indicaron que en ambos casos se presentaba el RP por lo que el significado real de este término podía ser diferente al definido por Libet.

Existen más críticas a este tipo de experimentos, es difícil saber si la decisión ha sido espontánea o deliberada, algunos investigadores [50] sugieren que si la decisión se realiza antes de 600ms podría considerarse como espontánea. En una evidencia completamente opuesta a la de Libet se encuentra la investigación [51] del PNAS, Proceedings of the National Academy of Sciences of the United States of America, donde se investiga el punto




Figura 3.1: Diseño del experimento.

de no retorno para cancelar un movimiento. El estudio encontró evidencias de que una acción puede ser inhibida después de manifestar el RP, por lo que esto supondría que existe al menos un pequeño margen de libre albedrío en los humanos.

Volviendo al diseño del experimento, Soon [1], para tratar de solucionar algunos de los problemas mencionados anteriormente proponen una investigación basada en el uso de la imagen por resonancia magnética funcional, fMRI, que permite detectar la zona del cerebro encargada de tomar una decisión, con el objetivo de mejorar la precisión del momento exacto en el que se toma la decisión.

Su prueba consistía en lo siguiente, [Figura 3.1](#), un sujeto se sentaba cómodamente delante de una pantalla en la que aparecían una serie de consonantes de forma aleatoria, bajo la condición de que no se podía repetir una hasta que no hubiese aparecido el resto (8 consonantes distintas), cada 500ms. Los sujetos tenían que permanecer relajados. A lo largo de la aparición de las letras, el sujeto debía pulsar una tecla cuando sintiese la necesidad de hacerlo. No tenían la obligación de balancear sus respuestas. Tras pulsar una tecla, la pantalla se ponía en blanco durante 2 segundos, después aparecía otra pantalla donde el sujeto intentaba recordar la letra presentada en el momento de pulsar el botón, en esta pantalla aparecían las tres últimas consonantes y un carácter '#' a modo de comodín en caso de olvidar su respuesta. La disposición de estas letras también era aleatoria. Tras elegir seleccionar la letra, la pantalla volvía a ponerse en blanco dos segundos y volvía a realizarse la prueba.

El estudio demostró que se producía actividad cerebral en la zona del córtex frontopolar hasta siete segundos antes de que el sujeto fuera cons-

ciente de la decisión de pulsar el botón.

En la investigación se uso validación cruzada con SVM para realizar la clasificación, obteniendo un precisión del 60 % en las predicciones.

Capítulo 4

Materiales y métodos

4.1. Datos

Comenzamos el problema con un conjunto de datos publicado en Zenodo [52]. Este dataset contiene la información del experimento realizado sobre 20 sujetos, bajo el protocolo experimental explicado en el estado del arte y resumido en la Figura 3.1. Tiene dos directorios donde se almacenan los datos de cada sujeto en formato CSV, el primero, 'Muse', contiene las variables, características, que el dispositivo wearable toma:

- **Timestamp:** fecha y hora con precisión de milisegundos de los datos captados. Es guardado en formato AAAA-MM-DD HH:mm:ss.fff, correspondiendo AAAA al año, MM al mes, DD al día, HH a la hora, mm al minuto, SS al segundo y fff al milisegundo.
- **Delta:** son las ondas cerebrales con mayor amplitud de onda, principalmente activas con las fases del sueño profundo, por lo que se relacionan con procesos que no dependen de un estado de consciencia. Estas ondas tienen una frecuencia de entre 1 y 4 Hz.
- **Theta:** son las ondas cerebrales con mayor amplitud de onda después de las ondas delta, presentes en etapas de calma profunda, relajación e inmersión en recuerdos, por lo que se asocian a una consciencia presente pero desconectada de la realidad y centrada en experiencias imaginarias. Estas ondas tienen una frecuencia de entre 4 y 8 Hz.
- **Alpha:** son las ondas con mayor amplitud de onda después de las ondas Theta, presentes en etapas de relajación como un paseo o mirar la televisión, por lo que se relacionan con procesos de calma profunda con consciencia presente. Estas ondas tienen una frecuencia de entre 7,5 y 13 Hz.
- **Beta:** son las ondas de menor amplitud, después de las ondas gamma, presentes en estados que requieren cierto nivel de atención o alerta,

en los que hay que ser consciente de los cambios que se producen a nuestro alrededor. Estas ondas tienen una frecuencia de entre 13 y 30 Hz.

- **Gamma:** son las ondas de menor amplitud, presentes en estados de vigilia, que se asocian a una ampliación del foco de atención y gestión de memoria. Estas ondas tienen una frecuencia de entre 30 y 44 Hz.
- **Raw:** son la representación de las señales eléctricas crudas captadas por Muse.
- **AUX_RIGHT:** ondas raw captadas por un sensor USB auxiliar.
- **Mellow:** relajación del usuario.
- **Concentration:** concentración del usuario.
- **Accelerometer (X, Y, Z):** detecta movimientos del dispositivo, inclinaciones hacia arriba, hacia abajo y hacia los lados.
- **Gyro (X, Y, Z):** movimiento del giroscopio durante el tiempo.
- **HeadBandOn:** indica si la bandana se encuentra en la cabeza.
- **HSI:** Horse Shoe Indicator, calidad de los sensores, el valor 1 indica excelente calidad, el valor 2 una calidad normal y el valor 4 una calidad mala [53].
- **Battery:** batería restante del dispositivo.
- **Elements:** distintas acciones que puede realizar el sujeto, tales como parpadear o apretar la mandíbula.

Estos datos fueron tomados con una frecuencia de muestreo de 256Hz.

En total contamos con 41 características ya que el dispositivo cuenta con 4 sensores que toman los datos de cada tipo de onda incluyendo los datos en crudo, raw, y la calidad de estos, HSI. De todas estas 'features' trabajaremos principalmente con los datos 'raw' ya que en ellos está presente toda la información que necesitamos.

Los sensores del dispositivo quedan situados sobre unas posiciones específicas de la cabeza, que siguen la nomenclatura del estándar conocido como sistema 10-10, [Figura 4.1](#) .

En este caso las posiciones utilizadas son las siguientes, [Figura 4.2](#) :




Figura 4.1: Sistema internacional 10-10 Fuente: <https://naxonlabs.com/blog/understanding-strategic-placement-sensors-eeeg-devices>




Figura 4.2: Imagen de (a) dispositivo EEG (Muse), que consta de cuatro electrodos (AF7, AF8, TP9 y TP10), y (b) distribución EEG de electrodos basada en el posicionamiento internacional 10/20. Fuente: <https://www.medrxiv.org/content/10.1101/2024.04.19.24306029v1.full>

Por otro lado, el directorio 'Local', contiene la información de los tiempos de cada una de las respuestas concretamente consta de los siguientes características:

- **ID:** identificador del participante del experimento. El identificador es un número entero, que comienza en 0 y tiene valores consecutivos. En nuestro caso concreto, alcanzará hasta 19.
- **Trial:** sesión del experimento en la que se han grabado los resultados. Una sesión comprende desde que se pulsa el botón de «Comenzar experimento» hasta que vuelve a aparecer. Es un número entero que comienza en 0 y tiene valores consecutivos. En nuestro caso concreto, alcanzará hasta 9.
- **Respuesta:** identificador de cada respuesta de cada sesión. Una respuesta comprende desde que aparece una pantalla en blanco hasta que se elige la letra visualizada en pantalla en el momento de sentir el impulso de pulsar una tecla. Es un número entero que comienza en 0 y tiene valores consecutivos, no es más que un identificador de una respuesta en una sesión.
- **Tiempo de inicio:** momento de inicio de la respuesta, es decir, momento en el que aparece una pantalla en blanco hasta que se da comienzo al proceso de toma de decisiones.
- **Tiempo de aparición de letras:** momento en el que comienzan a aparecer letras aleatorias en la pantalla. A partir de este momento, el participante puede pulsar la tecla derecha o izquierda cuando desee.
- **Tiempo de la pulsación:** momento en el que el participante pulsa la tecla P (derecha) o Q (izquierda).
- **Tecla elegida:** elección tomada por el participante. Tendrá como valores posibles P o Q.
- **Tiempo de aparición de la letra observada:** momento en el que aparece la letra que se le ha pedido recordar al usuario en el momento en el que toma la decisión de libre albedrío. Se interpreta como el momento de la decisión.
- **Letra observada:** respuesta al recuerdo de la letra que aparecía en pantalla en el momento de sentir el impulso de libre albedrío. Tendrá como valores posibles S, R, N, D, L, C, T, M o #.

A pesar de que contamos con 20 sujetos, dos de ellos no presentan datos en el directorio 'Local' por lo que los vamos a descartar y trabajaremos solo con 18 sujetos.

Los participantes se eligieron de forma equilibrado entre hombres y mujeres, con una edad de 18 a 25 años, para garantizar que todos los sujetos

se encuentran en la misma etapa de desarrollo cognitivo. Estos participantes no presentaban ninguna patología psicológica que afectase a la toma de decisiones. Tampoco tenían problemas de visión ya que esto podía influir en la lectura de los caracteres en pantalla. Todos los participantes elegidos debían tener la misma mano dominante, por simplicidad se eligió seleccionar a los diestros, de este modo se evitarían preferencias a la hora de realizar una decisión influenciadas por este factor. Para garantizar estos requisitos se realizó una entrevista previa al experimento a todos los pacientes.



Figura 4.3: Dispositivo wearable utilizado para la obtención de los datos del EEG. Fuente: <https://choosemuse.com/products/muse-s-gen-2>

4.2. Planificación

La mayoría de los trabajos de aprendizaje automático siguen el mismo enfoque. Recopilación de los datos, manipulación, extracción de características y finalmente el entrenamiento de modelos, nosotros seguiremos un enfoque similar.

Para llevar a cabo todas estas tareas he aplicado un enfoque ágil [54] para el desarrollo del software, donde iba realizando pequeñas entregas del proyecto, software y memoria, cada dos semanas aproximadamente, estas entregas se realizaban mediante releases [55] en GitHub. Aplicar este enfoque me ha permitido mejorar algunas partes de las primeras fases una vez finalizadas estas, esto no hubiese sido posible con una metodología tradicional como el desarrollo en cascada [56] donde para iniciar una fase de desarrollo es estrictamente necesario finalizar la etapa anterior.

Las releases son iteraciones software donde se pueden empaquetar versiones junto con anotaciones y archivos adjuntos, esto facilita el seguimiento y la descarga de versiones. Podemos ver una manifestación de estas releases en el diagrama de Gantt, Figura 4.5 , donde cada bloque en negrita representa una entrega/hito subdividido en una serie de subtareas para facilitar el seguimiento y desarrollo.

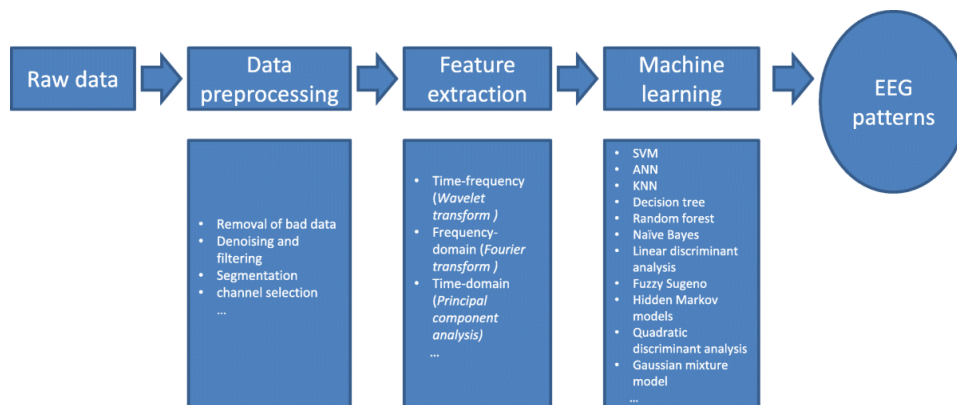


Figura 4.4: Pasos de un proyecto de ML

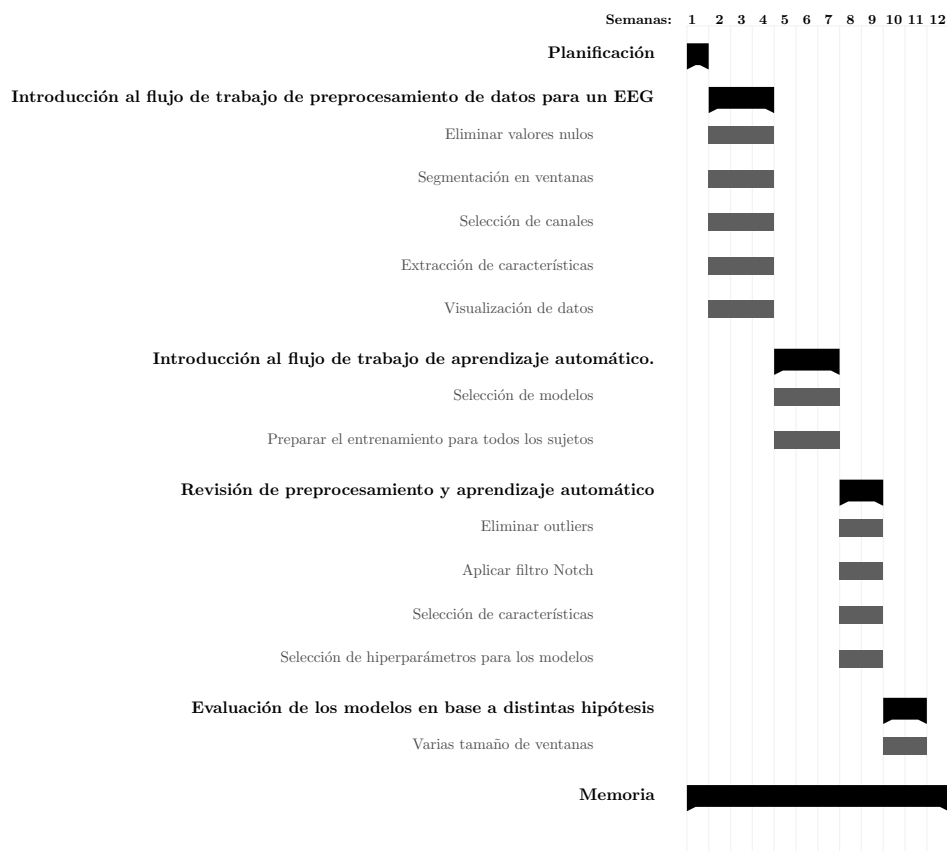


Figura 4.5: Diagrama de Gantt con la planificación temporal del proyecto.

4.3. Tecnologías utilizadas

Dado que no tenemos restricciones a la hora de utilizar tecnologías utilizaré Python para desarrollar este proyecto debido a su facilidad de uso, su gran comunidad y principalmente el gran ecosistema de bibliotecas que tiene para trabajar en este campo de la informática. Las bibliotecas que vamos a utilizar son las siguientes:

os Nos permite interactuar con el sistema operativo para movernos por el sistema de archivos y cargar los documentos en nuestro programa.

pandas Es una biblioteca para el análisis de datos. Añade estructuras donde podremos colocar nuestros ficheros. También nos permite manipular y filtrar dichas estructuras facilitandonos la limpieza de datos.

numpy Se centra en el cálculo numérico y científico. Ofrece arrays multi-dimensionales y funciones matemáticas eficientes.

Matplotlib Se utiliza para visualización de datos, principalmente la usaremos para crear gráficas.

tsfresh Está diseñado para extraer características de series temporales.

Scikit-Learn Biblioteca para machine learning.

4.4. Costes

La estimación del coste de este proyecto se realizará a partir de la manipulación de los datos, es decir no se tendrá en cuenta la recopilación de estos.

Nos basaremos en el número de créditos destinados a la asignatura del TFG ya que estos reflejan aproximadamente el esfuerzo invertido en este proyecto.

La asignatura Proyecto Fin de Grado consta de 12 créditos, asignado una carga de trabajo de 25 horas por créditos obteniendo un total de 300 horas de trabajo que se repartirán a lo largo de 12 semanas.

Se estima que un Ingeniero de Aprendizaje Automático en España cobra unos 38000€ al año que supondrían un pago de 19,79€ la hora [57][58].

En cuanto a los gastos de hardware añadiremos los de la [Tabla 4.1](#). Este tipo de gastos suele ir asociado a un periodo de amortización. La amortización [59] es una manera de repartir la pérdida de valor de un producto(activo) a lo largo del tiempo, en este caso a lo largo del desarrollo del TFG. El material informático tiene un periodo máximo de amortización de 10 años y una tasa de amortización máxima del 26 % [60], es decir, podemos amortizar un 26 % del valor total de producto cada año, por lo que podemos amortizar completamente el material informático en un periodo de 4 años, 1460 días concretamente.

De este modo el coste de un producto a amortizar en el proyecto, CP, se puede expresar en relación a su periodo de amortización A, y su coste total, CT, de la siguiente manera $CP = \frac{CT}{A}$.

| Producto | Tipo | CT | A | CP |
|--------------------------------|----------|---------|------|-----------|
| HP Pavilion Gaming 15-EC1012NS | Portátil | 900,00€ | 1460 | 0,62€/día |
| Razer Orochi V2 | Ratón | 50,00€ | 1460 | 0,03€/día |
| Total | | | | 0,65€/día |

Tabla 4.1: Costes hardware

| Sección | Coste |
|-----------------|----------|
| Costes humanos | 5937€ |
| Costes hardware | 54,6€ |
| Coste total | 5991,6 € |

Tabla 4.2: Coste final del proyecto

Finalmente juntando todos los gastos, podemos estimar el coste del proyecto en 5991,6€, ver [Tabla 4.2](#)

Capítulo 5

Experimentos

En esta sección explicaré los procedimientos que he realizado desde que recibí los datos hasta que obtuve los resultados. Para ello repasaré cada una de las etapas del desarrollo, [Figura 4.4](#) :

5.1. Preprocesamiento

He realizado las siguientes transformaciones.

Limpieza de datos En primer lugar utilicé indicador HSI que indica el estado de cada electrodo. Tras analizar este marcador he optado por descartar los sensores TP9 y TP10 debido a que suelen presentar mayor cantidad de errores/datos de peor calidad. El valor HSI oscila entre 1 y 4, siendo el valor 1 los datos de mayor calidad y 4 los de peor. En el 61 % de los archivos ambos sensores tienen un valor superior a 2 y en el 72 % de los casos al menos uno de los dos sensores tienen una media superior a 2. En cambio los sensores AF7 y AF8 en ningún archivo superan una media de 1,3 por este motivo he decidido trabajar exclusivamente con este par de sensores.

Después eliminé los outliers utilizando exclusivamente los datos entre el percentil 1 y 92,5 de los datos en crudo de cada sensor utilizado. Inicialmente opté por usar el percentil 1 y 99 pero debido a ficheros con demasiado ruido en los valores superiores tuve que reducir el percentil a 95, donde aún encontraba valores atípicos, por lo que finalmente tuve que reducirlo hasta el 92,5. También probé a utilizar umbrales fijos en los 700 y 900 μ V pero observé que los percentiles producían mejores resultados en los modelos.

Finalmente eliminé los datos infinitos/nulos y apliqué un filtro Notch

de 50Hz. Inicialmente pensaba que los datos en crudo ya presentaban este filtro de 50Hz, destinado a atenuar las señales dentro de un rango de frecuencias, permitiendo que el resto de señales pasen sin problemas [61], concretamente estaba pensado para el ruido de la red eléctrica, según el país el ruido está presente en los 50Hz o 60Hz. Pensaba esto debido a que es lo que se menciona en el manual de la aplicación utilizada para la extracción de los datos [62], pero tras analizar las frecuencias presentes en el primer fichero de datos mediante la Transformada de Fourier, Figura 5.1, y en una ventana concreta, Figura 5.2, me di cuenta de que precisamente había una señal bastante potente en los 50Hz. Tras ver esto decidí aplicar a las ventanas dicho filtro y obtuve el siguiente resultado, Figura 5.3. Inicialmente las ventanas se veían de esta manera, Figura 5.4, y tras aplicar el filtro pasaron a verse de la siguiente manera Figura 5.5.

Segmentación También conocido como 'epoching' [63] se refiere a la extracción de ventanas temporales de datos, es decir, un array de valores, situadas en los momentos relevantes del experimento, en este caso entorno al tiempo de respuesta, permitiéndonos posteriormente, extraer características que sintetizaran estos datos. Comenzamos con ventanas con un tamaño de 1 segundo e iremos probando varios tamaños de ventanas hasta llegar a ventanas con un tamaño de 10 segundos, ya que se cree que existe información en el subconsciente sobre la decisión que se va a tomar hasta 10 segundos antes de manifestar la decisión[1].

Entrando en los detalles de la selección de ventanas, para crear una, hay que seleccionar una de las respuestas de los archivos 'locales', observar el momento en el que se ha pulsado la tecla y finalmente buscar dentro del csv 'muse' las datos cuyo TimeStamp se encuentre situado dentro de los límites temporales establecidos, por ejemplo para las ventanas de 1 segundos, he seleccionado 200 milisegundos de postdecisión (común entre todos los tipos de ventanas) y 800ms de predecisión. Dado que nuestro dispositivo cuenta con una tasa de muestreo de 256Hz las ventanas de 1 segundo tendrán algo menos 256 datos, ya que normalmente se descarta algún valor erróneo en cada ventana, de hecho, si se pierden más del 10 % de los datos de una ventana, he decidido que se descarte para que no influya negativamente en los modelos. Podemos ver con cuantas ventanas empezamos y con cuantas finalmente entrenamos y evaluamos el modelo en Apéndice A.




Figura 5.1: Frecuencias presentes en el archivo 1

5.2. Extracción de características

En esta sección he utilizado `tsfresh` [18][19] sobre las ventanas de datos con el objetivo de generar características representativas. Usé la función `'extract_features'` [64] esta devolverá unas 780 características para cada canal, muchas de ellas poco relevantes, por lo que para filtrar las características y utilizar las más importantes haré uso de otras técnicas de selección de características, en concreto he realizado lo siguiente: Inicialmente, hice uso de la selección de características de `tsfresh`, pero esta no devolvía ningún resultado, para solventar esto hice uso de una tabla de relevancia, que también se puede calcular con este paquete, en esta tabla podemos ver la influencia de cada variable sobre la variable a predecir, para ello se basa en pruebas univariadas y el p-valor [24]. Posteriormente pensé en utilizar PCA pero en el paper [65] no obtenían buenos resultados tras aplicar esta técnica por lo que decidí optar por otras opciones utilizadas en dicha investigación. Utilicé una combinación de las siguientes métodos, en primer lugar un filtrado por p-valor, posteriormente hice uso de `'mRMR'`, "minimum Redundancy - Maximum Relevance" [66], tal y como realizan en [65], este método usa el coeficiente de correlación de Pearson [67] para tener en cuenta la redundancia y una de sus tres variantes, f-statistic [68], kolmogorov-smirnov [69] o




Figura 5.2: Frecuencias presentes en la primera ventana (1 segundo) de datos del fichero 1.

random forest, para tener en cuenta la relevancia.

Finalmente para combinar ambos resultados utilicé las características comunes a ambas técnicas, para intentar garantizar el uso de features relevantes. En algunas ocasiones, juntar las características comunes resultaba en menos de 10 características, en estos casos utilizaba solos las características comunes a los 3 métodos mRMR.

Para concluir el experimento entrené los siguientes modelos:

Random Forest - RF Con los siguientes hiperparámetros:

- 'n_estimators': [400]
- 'min_samples_split': [5]
- 'max_depth': [10]

XGBoost - XGB Con los siguientes hiperparámetros:

- 'n_estimators': [200]
- 'learning_rate': [0.2]




Figura 5.3: Frecuencias presentes en la primera ventana (1 segundo) de datos del fichero 1 tras el filtro de 50Hz.

- 'max_depth': [7]
- 'colsample_bytree': [0.6]
- 'gamma': [0]

Support Vector Machine - SVM Con los siguientes hiperparámetros:

- 'kernel': ['linear']
- 'C': [0.1]
- 'gamma': ['auto']

A continuación presentaré para cada tamaño de ventana el mejor modelo asociado a cada sujeto, las tablas correspondientes se encuentran entre la [Tabla 5.1](#) y la [Tabla 5.5](#). En el [Apéndice A](#) se puede ver el balance los datos de cada sujeto y tamaño de ventana.

Para intentar decidir cual es el mejor tamaño de ventana para este problema, he creado la [Figura 5.6](#) y la [Tabla 5.6](#), donde podemos ver el valor G-Mean asociado a cada sujeto y ventana. Los resultados en la gráfica son bastante similares por lo que es difícil decidir que tamaño de ventana es

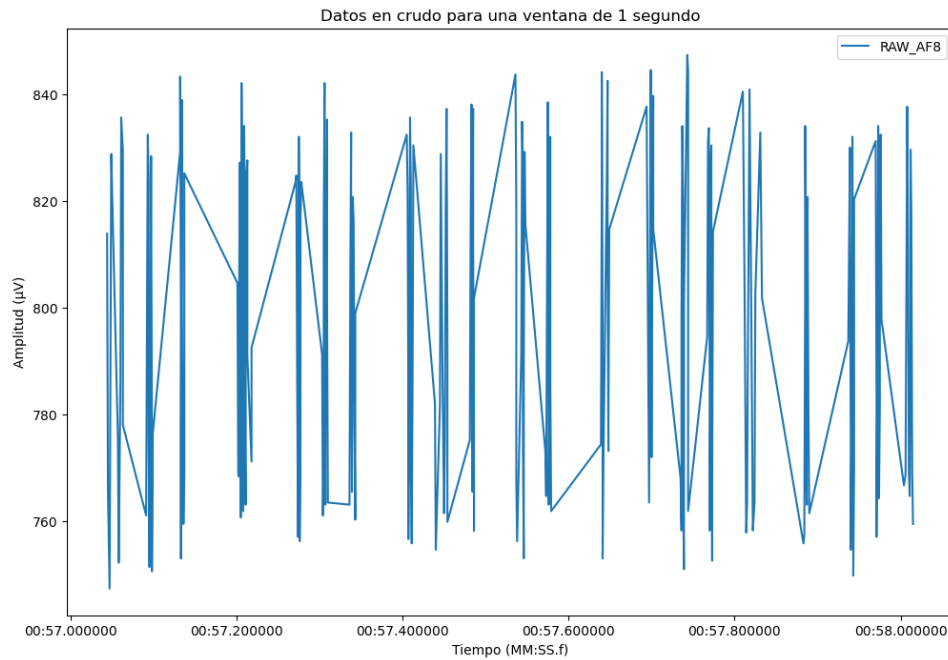


Figura 5.4: Datos de la ventana de 1 segundo.

mejor, solo podemos concluir que todos los tamaños aportan cierta información para predecir el resultado, en cambio con el resumen de los resultados podemos ver que las ventanas de 1 segundo son las que han obtenido mejores resultado en media.

Basandome en los resultados de la investigación de inicial (60 % accuracy) creo que he obtenido unos 'buenos' resultados. El principal motivo de estos resultados se debe a que cada para cada sujeto y tamaño de ventana se ha realizado una selección de características diferentes, por lo que son completamente específicos para cada problema. De cara a realizar más experimentos, se podría probar a utilizar un conjunto de características comunes para todos los ficheros, este conjunto se podría crear a partir de la unión de las características utilizadas en cada caso, de hecho, se podría utilizar este nuevo superconjunto como punto de partida para realizar experimentos intersujeto, es decir, realizar predicciones para cualquier sujeto usando los datos de entrenamiento de todos los participantes.

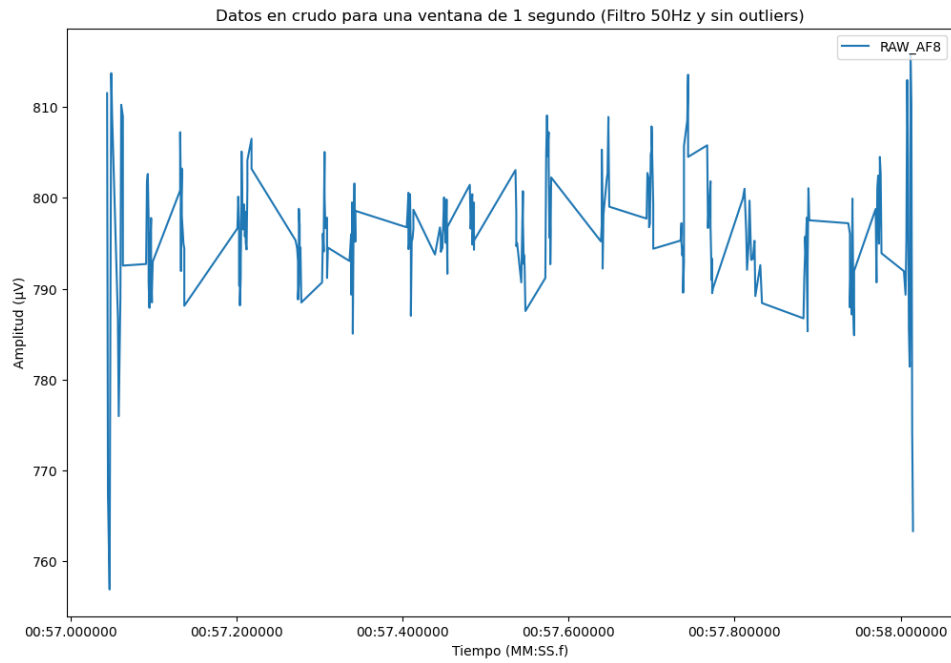


Figura 5.5: Datos de la ventana de 1 segundo tras el filtro de 50Hz.




Figura 5.6: G-Mean en todos los sujetos y ventanas.

| Sujeto y modelo | g_mean | acc | bal_acc | precision | specificity | recall | f1_m |
|-------------------|-------------------|------------------|-------------------|------------------|-------------------|-------------------|-------------------|
| 0 - 'RF' | 0.724432 | 0.740741 | 0.724432 | 0.732353 | 0.636364 | 0.8125 | 0.727273 |
| 1 - 'SVM' | 0.661053 | 0.636364 | 0.661053 | 0.675862 | 0.48 | 0.842105 | 0.633333 |
| 10 - 'SVM' | 0.791667 | 0.791667 | 0.791667 | 0.811111 | 0.666667 | 0.916667 | 0.78836 |
| 11 - 'RF/SVM' | 0.9375 | 0.92 | 0.9375 | 0.909091 | 1 | 0.875 | 0.916667 |
| 12 - 'SVM' | 0.9 | 0.894737 | 0.9 | 0.909091 | 0.8 | 1 | 0.894444 |
| 13 - 'RF/XGB/SVM' | 0.833333 | 0.833333 | 0.833333 | 0.875 | 0.666667 | 1 | 0.828571 |
| 14 - 'SVM' | 0.763889 | 0.761905 | 0.763889 | 0.759091 | 0.75 | 0.777778 | 0.759725 |
| 15 - 'RF' | 0.816667 | 0.818182 | 0.816667 | 0.816667 | 0.833333 | 0.8 | 0.816667 |
| 16 - 'SVM' | 0.954545 | 0.95 | 0.954545 | 0.95 | 0.909091 | 1 | 0.949875 |
| 17 - 'RF' | 0.823684 | 0.862069 | 0.823684 | 0.866071 | 0.947368 | 0.7 | 0.838889 |
| 18 - 'RF' | 0.597222 | 0.588235 | 0.597222 | 0.606061 | 0.444444 | 0.75 | 0.582456 |
| 19 - 'RF' | 0.690476 | 0.6875 | 0.690476 | 0.6875 | 0.666667 | 0.714286 | 0.686275 |
| 4 - 'RF' | 0.714583 | 0.709677 | 0.714583 | 0.734091 | 0.5625 | 0.866667 | 0.704762 |
| 5 - 'XGB' | 0.807598 | 0.804878 | 0.807598 | 0.800239 | 0.823529 | 0.791667 | 0.801932 |
| 6 - 'RF' | 0.916667 | 0.9 | 0.916667 | 0.9 | 1 | 0.833333 | 0.89899 |
| 7 - 'SVM' | 0.854167 | 0.863636 | 0.854167 | 0.82381 | 0.875 | 0.833333 | 0.836228 |
| 8 - 'XGB' | 0.72381 | 0.722222 | 0.72381 | 0.718266 | 0.733333 | 0.714286 | 0.71875 |
| 9 - 'SVM' | 0.803922 | 0.869565 | 0.803922 | 0.844444 | 0.666667 | 0.941176 | 0.820779 |
| Average | 0.7953 \pm 0.09 | 0.7975 \pm 0.1 | 0.7953 \pm 0.09 | 0.801 \pm 0.09 | 0.7479 \pm 0.16 | 0.8427 \pm 0.09 | 0.7891 \pm 0.09 |

Tabla 5.1: Resultados para las ventanas de 1 segundo.

| Sujeto y modelo | g_mean | acc | bal_acc | precision | specificity | recall | f1_m |
|-------------------|-------------------|------------------|-------------------|-------------------|-------------------|-------------------|------------------|
| 0 - 'SVM' | 0.804511 | 0.818182 | 0.804511 | 0.821429 | 0.714286 | 0.894737 | 0.809615 |
| 1 - 'RF' | 0.558777 | 0.529412 | 0.558777 | 0.569444 | 0.344828 | 0.772727 | 0.520376 |
| 10 - 'RF' | 0.739011 | 0.740741 | 0.739011 | 0.741667 | 0.785714 | 0.692308 | 0.73931 |
| 11 - 'SVM' | 0.7 | 0.666667 | 0.7 | 0.678571 | 0.8 | 0.6 | 0.660633 |
| 12 - 'SVM' | 0.854545 | 0.857143 | 0.854545 | 0.861111 | 0.8 | 0.909091 | 0.855835 |
| 13 - 'RF/XGB' | 0.65 | 0.666667 | 0.65 | 0.666667 | 0.8 | 0.5 | 0.649351 |
| 14 - 'XGB' | 0.777778 | 0.766667 | 0.777778 | 0.766667 | 0.833333 | 0.722222 | 0.76431 |
| 15 - 'SVM' | 0.731061 | 0.73913 | 0.731061 | 0.772321 | 0.916667 | 0.545455 | 0.72619 |
| 16 - 'SVM' | 0.732143 | 0.733333 | 0.732143 | 0.732143 | 0.75 | 0.714286 | 0.732143 |
| 17 - 'SVM' | 0.768398 | 0.78125 | 0.768398 | 0.758333 | 0.809524 | 0.727273 | 0.76246 |
| 18 - 'SVM' | 0.616667 | 0.6 | 0.616667 | 0.613636 | 0.533333 | 0.7 | 0.599359 |
| 19 - 'RF/XGB/SVM' | 0.725 | 0.722222 | 0.725 | 0.722222 | 0.7 | 0.75 | 0.721362 |
| 4 - 'XGB' | 0.705882 | 0.705882 | 0.705882 | 0.708772 | 0.647059 | 0.764706 | 0.704861 |
| 5 - 'RF/SVM' | 0.705 | 0.711111 | 0.705 | 0.70749 | 0.65 | 0.76 | 0.705882 |
| 6 - 'RF' | 0.944444 | 0.952381 | 0.944444 | 0.961538 | 0.888889 | 1 | 0.950588 |
| 7 - 'RF' | 0.833333 | 0.916667 | 0.833333 | 0.95 | 1 | 0.666667 | 0.873684 |
| 8 - 'RF/XGB' | 0.757143 | 0.75 | 0.757143 | 0.75 | 0.8 | 0.714286 | 0.748252 |
| 9 - 'XGB' | 0.833333 | 0.916667 | 0.833333 | 0.95 | 0.666667 | 1 | 0.873684 |
| Average | 0.7465 \pm 0.09 | 0.7541 \pm 0.1 | 0.7465 \pm 0.09 | 0.7629 \pm 0.11 | 0.7467 \pm 0.14 | 0.7463 \pm 0.13 | 0.7443 \pm 0.1 |

Tabla 5.2: Resultados para las ventanas de 2,5 segundos.

| Sujeto y modelo | g_mean | acc | bal_acc | precision | specificity | recall | f1_m |
|----------------------|---------------|------------|---------------|--------------|---------------|---------------|---------------|
| 0 - 'XGB' | 0.759398 | 0.787879 | 0.759398 | 0.819444 | 0.571429 | 0.947368 | 0.766431 |
| 1 - 'RF' | 0.655956 | 0.627451 | 0.655956 | 0.677679 | 0.448276 | 0.863636 | 0.622222 |
| 10 - 'XGB' | 0.887363 | 0.888889 | 0.887363 | 0.891667 | 0.928571 | 0.846154 | 0.888276 |
| 11 - 'RF' | 0.678571 | 0.741935 | 0.678571 | 0.703804 | 0.5 | 0.857143 | 0.686869 |
| 12 - 'RF' | 0.863636 | 0.863636 | 0.863636 | 0.866667 | 0.818182 | 0.909091 | 0.863354 |
| 13 - 'RF/XGB' | 1 | 1 | 1 | 1 | 1 | 1 | 1 |
| 14 - 'SVM' | 0.758772 | 0.741935 | 0.758772 | 0.745833 | 0.833333 | 0.684211 | 0.739496 |
| 15 - 'XGB' | 0.916667 | 0.913043 | 0.916667 | 0.923077 | 0.833333 | 1 | 0.912879 |
| 16 - 'SVM' | 0.65873 | 0.6875 | 0.65873 | 0.708333 | 0.888889 | 0.428571 | 0.65368 |
| 17 - 'XGB' | 0.811688 | 0.78125 | 0.811688 | 0.78125 | 0.714286 | 0.909091 | 0.775776 |
| 18 - 'XGB' | 0.85 | 0.84 | 0.85 | 0.836538 | 0.8 | 0.9 | 0.837662 |
| 19 - 'RF' | 0.875 | 0.888889 | 0.875 | 0.916667 | 1 | 0.75 | 0.883117 |
| 4 - 'RF/XGB' | 0.676471 | 0.676471 | 0.676471 | 0.682143 | 0.764706 | 0.588235 | 0.673932 |
| 5 - 'SVM' | 0.71 | 0.711111 | 0.71 | 0.708333 | 0.7 | 0.72 | 0.70881 |
| 6 - 'SVM' | 0.638889 | 0.666667 | 0.638889 | 0.666667 | 0.444444 | 0.833333 | 0.637037 |
| 7 - 'XGB' | 0.888889 | 0.916667 | 0.888889 | 0.888889 | 0.944444 | 0.833333 | 0.888889 |
| 8 - 'XGB' | 0.671429 | 0.694444 | 0.671429 | 0.6875 | 0.533333 | 0.809524 | 0.674074 |
| 9 - 'XGB/SVM' | 0.694444 | 0.791667 | 0.694444 | 0.721053 | 0.5 | 0.888889 | 0.70516 |
| Average | 0.7776 ± 0.11 | 0.79 ± 0.1 | 0.7776 ± 0.11 | 0.7903 ± 0.1 | 0.7346 ± 0.19 | 0.8205 ± 0.14 | 0.7732 ± 0.11 |

Tabla 5.3: Resultados para las ventanas de 5 segundos.

| Sujeto y modelo | g_mean | acc | bal_acc | precision | specificity | recall | f1_m |
|-------------------|---------------|-----------------|---------------|-----------------|---------------|---------------|-----------------|
| 0 - 'RF' | 0.723684 | 0.757576 | 0.723684 | 0.7975 | 0.5 | 0.947368 | 0.727273 |
| 1 - 'XGB' | 0.742163 | 0.72549 | 0.742163 | 0.745238 | 0.62069 | 0.863636 | 0.725385 |
| 10 - 'RF' | 0.817949 | 0.821429 | 0.817949 | 0.822917 | 0.866667 | 0.769231 | 0.819355 |
| 11 - 'XGB' | 0.730952 | 0.741935 | 0.730952 | 0.712719 | 0.7 | 0.761905 | 0.718182 |
| 12 - 'RF/XGB' | 0.636364 | 0.636364 | 0.636364 | 0.641026 | 0.727273 | 0.545455 | 0.633333 |
| 13 - 'RF/XGB' | 0.8 | 0.8 | 0.8 | 0.857143 | 0.6 | 1 | 0.791667 |
| 14 - 'XGB' | 0.864035 | 0.870968 | 0.864035 | 0.864035 | 0.833333 | 0.894737 | 0.864035 |
| 15 - 'RF/XGB' | 0.69697 | 0.695652 | 0.69697 | 0.69697 | 0.666667 | 0.727273 | 0.695652 |
| 16 - 'XGB' | 0.809524 | 0.8125 | 0.809524 | 0.809524 | 0.833333 | 0.785714 | 0.809524 |
| 17 - 'RF/XGB' | 0.746753 | 0.78125 | 0.746753 | 0.759091 | 0.857143 | 0.636364 | 0.751938 |
| 18 - 'SVM' | 0.830303 | 0.846154 | 0.830303 | 0.856209 | 0.933333 | 0.727273 | 0.8375 |
| 19 - 'SVM' | 0.875 | 0.888889 | 0.875 | 0.916667 | 1 | 0.75 | 0.883117 |
| 4 - 'RF' | 0.705882 | 0.705882 | 0.705882 | 0.708772 | 0.647059 | 0.764706 | 0.704861 |
| 5 - 'SVM' | 0.735 | 0.755556 | 0.735 | 0.782452 | 0.55 | 0.92 | 0.736842 |
| 6 - 'XGB' | 0.680556 | 0.666667 | 0.680556 | 0.680556 | 0.777778 | 0.583333 | 0.666667 |
| 7 - 'SVM' | 0.777778 | 0.833333 | 0.777778 | 0.777778 | 0.888889 | 0.666667 | 0.777778 |
| 8 - 'SVM' | 0.828571 | 0.833333 | 0.828571 | 0.828571 | 0.8 | 0.857143 | 0.828571 |
| 9 - 'RF' | 0.805556 | 0.875 | 0.805556 | 0.847368 | 0.666667 | 0.944444 | 0.823096 |
| Average | 0.7671 ± 0.06 | 0.7804 ± 0.07 | 0.7671 ± 0.06 | 0.7836 ± 0.07 | 0.7483 ± 0.13 | 0.7858 ± 0.12 | 0.7664 ± 0.07 |

Tabla 5.4: Resultados para las ventanas de 7,5 segundos.

| Sujeto y modelo | g_mean | acc | bal_acc | precision | specificity | recall | f1_m |
|-------------------|------------------|------------------|------------------|------------------|-------------------|-------------------|------------------|
| 0 - 'SVM' | 0.75 | 0.787879 | 0.75 | 0.865385 | 0.5 | 1 | 0.755556 |
| 1 - 'SVM' | 0.594044 | 0.588235 | 0.594044 | 0.592593 | 0.551724 | 0.636364 | 0.587601 |
| 10 - 'RF' | 0.812821 | 0.821429 | 0.812821 | 0.838889 | 0.933333 | 0.692308 | 0.815547 |
| 11 - 'SVM' | 0.804762 | 0.806452 | 0.804762 | 0.780702 | 0.8 | 0.809524 | 0.788636 |
| 12 - 'RF' | 0.545455 | 0.545455 | 0.545455 | 0.547009 | 0.454545 | 0.636364 | 0.541667 |
| 13 - 'SVM' | 0.9 | 0.9 | 0.9 | 0.916667 | 0.8 | 1 | 0.89899 |
| 14 - 'SVM' | 0.671053 | 0.709677 | 0.671053 | 0.69697 | 0.5 | 0.842105 | 0.675958 |
| 15 - 'XGB' | 0.617424 | 0.608696 | 0.617424 | 0.638393 | 0.416667 | 0.818182 | 0.596491 |
| 16 - 'SVM' | 0.708647 | 0.69697 | 0.708647 | 0.705556 | 0.631579 | 0.785714 | 0.696691 |
| 17 - 'SVM' | 0.837662 | 0.84375 | 0.837662 | 0.825 | 0.857143 | 0.818182 | 0.830329 |
| 18 - 'SVM' | 0.79697 | 0.807692 | 0.79697 | 0.80625 | 0.866667 | 0.727273 | 0.800307 |
| 19 - 'XGB' | 0.825 | 0.833333 | 0.825 | 0.837662 | 0.9 | 0.75 | 0.828571 |
| 4 - 'SVM' | 0.676471 | 0.676471 | 0.676471 | 0.677083 | 0.647059 | 0.705882 | 0.67619 |
| 5 - 'SVM' | 0.73 | 0.733333 | 0.73 | 0.73 | 0.7 | 0.76 | 0.73 |
| 6 - 'RF' | 0.875 | 0.857143 | 0.875 | 0.875 | 1 | 0.75 | 0.857143 |
| 7 - 'SVM' | 0.666667 | 0.75 | 0.666667 | 0.666667 | 0.833333 | 0.5 | 0.666667 |
| 8 - 'XGB' | 0.709524 | 0.694444 | 0.709524 | 0.70625 | 0.8 | 0.619048 | 0.694208 |
| 9 - 'SVM' | 0.833333 | 0.833333 | 0.833333 | 0.78125 | 0.833333 | 0.833333 | 0.798319 |
| Average | 0.7419 \pm 0.1 | 0.7497 \pm 0.1 | 0.7419 \pm 0.1 | 0.7493 \pm 0.1 | 0.7236 \pm 0.17 | 0.7602 \pm 0.12 | 0.7355 \pm 0.1 |

Tabla 5.5: Resultados para las ventanas de 10 segundos.

| Tamaño ventana(s) | g_mean | acc | bal_acc | precision | specificity | recall | f1_m |
|-------------------|-------------------------------------|------------------------------------|-------------------------------------|------------------------------------|-------------------------------------|-------------------------------------|-------------------------------------|
| 1 | 0.7953 \pm 0.09 | 0.7975 \pm 0.1 | 0.7953 \pm 0.09 | 0.801 \pm 0.09 | 0.7479 \pm 0.16 | 0.8427 \pm 0.09 | 0.7891 \pm 0.09 |
| 2.5 | 0.7465 \pm 0.09 | 0.7541 \pm 0.1 | 0.7465 \pm 0.09 | 0.7629 \pm 0.11 | 0.7467 \pm 0.14 | 0.7463 \pm 0.13 | 0.7443 \pm 0.1 |
| 5 | 0.7776 \pm 0.11 | 0.79 \pm 0.1 | 0.7776 \pm 0.11 | 0.7903 \pm 0.1 | 0.7346 \pm 0.19 | 0.8205 \pm 0.14 | 0.7732 \pm 0.11 |
| 7.5 | 0.7671 \pm 0.06 | 0.7804 \pm 0.07 | 0.7671 \pm 0.06 | 0.7836 \pm 0.07 | 0.7483 \pm 0.13 | 0.7858 \pm 0.12 | 0.7664 \pm 0.07 |
| 10 | 0.7419 \pm 0.1 | 0.7497 \pm 0.1 | 0.7419 \pm 0.1 | 0.7493 \pm 0.1 | 0.7236 \pm 0.17 | 0.7602 \pm 0.12 | 0.7355 \pm 0.1 |

Tabla 5.6: Resumen (media y desviación típica) de los distintos tamaños de ventana.

Capítulo 6

Conclusiones

Tal y como se propuso en un inicio, la realización de este proyecto ha permitido estudiar el uso de técnicas de aprendizaje automático para la predicción de decisiones. Estas técnicas han sido capaces de identificar ciertos patrones, que han permitido mejorar el porcentaje de acierto de una predicción, más allá de la probabilidad aleatoria de acertar del 50 % de la veces, llegando a alcanzar en algunos casos 90 % de acierto, incluso un 100 % para uno de los ficheros, aunque esto suene muy bien, no en todos los casos se han llegado a obtener tan buenos resultados, en media los resultados oscilan entre el 74 y 80 % tanto en accuracy como en g-mean. Estos resultados podrían confirmar las conclusiones alcanzadas en el paper de Soon en 2017 [46], donde obtienen un 60 % de precisión a la hora de clasificar, concluyendo que el principal motivo de los bajos resultados es que existe una influencia causal en la mente consciente, a pesar de esto se puede concluir que existen ciertas señales cerebrales que contribuyen a la toma de decisiones aunque no determinen la decisión por completo.

Existen un gran margen de mejora y mucho trabajo por hacer. De cara al avance de la neurociencia, sería de gran utilidad mejorar la explicabilidad de los modelos, más allá de la selección de características. También sería de gran interés seguir realizando la investigación abordando la predicción intersujeto, intentar crear un modelo capaz de generalizar la predicción para cualquier persona, aunque cabe esperar que la investigación en este tema dará lugar a peores resultados, en un principio, debido a la variabilidad existente entre sujetos.

También se podría utilizar otras técnicas en la selección de características tales como DSP [70][71], que detecta el premovimiento o bien indagar más en la selección automática de características. El uso de otros modelos podría resultar interesante, existen algunas investigaciones donde se usan redes neuronales convolucionales [72], CNN [73], donde se crean imágenes a

partir de los datos del EEG, dichas imágenes están basadas en la Short Time Fourier Transform, STFT, esta técnica devuelve unos resultados entorno al 73.9 % de accuracy, en ese paper mencionan que las CNN superan a las redes neuronales, SVM y autoencoders apilados. Otra alternativa similar a STFT podría ser el uso de wavelets ¹

La realización de este TFG ha supuesto un gran desafío. Me ha permitido afianzar mis conocimientos en aprendizaje automático y he podido trabajar en varios campos completamente nuevos para mí, como las series temporales y la neurociencia.

¹Excelente [video explicativo](#) de los wavelets .

Apéndice A

Estadísticas de datos para cada tamaño de ventana

La principal diferencia entre las siguientes tablas es el número de respuestas finales, ya que cuando más grande es la ventana menos probabilidades hay de que esta se descarte debido a que se han perdido más del 10 % de valores.

El resto de valores son meramente informativos [Tabla A.1](#)

| local | muse | #res_ini | #res_fin | b.c. 0(p)(total) | b.c. 0(train) | b.c. 0(test) |
|-----------|------------|----------|----------|------------------|---------------|--------------|
| results0 | museData0 | 164 | 131 | 0.603659 | 0.586538 | 0.592593 |
| results1 | museData1 | 254 | 218 | 0.594488 | 0.591954 | 0.431818 |
| results10 | museData10 | 137 | 117 | 0.49635 | 0.473118 | 0.5 |
| results11 | museData11 | 155 | 124 | 0.567742 | 0.545455 | 0.64 |
| results12 | museData12 | 107 | 94 | 0.485981 | 0.506667 | 0.473684 |
| results13 | museData13 | 49 | 28 | 0.469388 | 0.5 | 0.5 |
| results14 | museData14 | 153 | 101 | 0.627451 | 0.6625 | 0.428571 |
| results15 | museData15 | 115 | 109 | 0.521739 | 0.551724 | 0.454545 |
| results16 | museData16 | 161 | 99 | 0.416149 | 0.417722 | 0.45 |
| results17 | museData17 | 158 | 141 | 0.443038 | 0.482143 | 0.344828 |
| results18 | museData18 | 128 | 83 | 0.5 | 0.530303 | 0.470588 |
| results19 | museData19 | 90 | 76 | 0.477778 | 0.5 | 0.4375 |
| results4 | museData4 | 168 | 154 | 0.547619 | 0.569106 | 0.483871 |
| results5 | museData5 | 223 | 202 | 0.515695 | 0.496894 | 0.585366 |
| results6 | museData6 | 104 | 48 | 0.480769 | 0.421053 | 0.6 |
| results7 | museData7 | 119 | 110 | 0.302521 | 0.318182 | 0.272727 |
| results8 | museData8 | 178 | 178 | 0.494382 | 0.471831 | 0.583333 |
| results9 | museData9 | 116 | 114 | 0.663793 | 0.659341 | 0.73913 |

Tabla A.1: Balance de clases para las ventanas de 1 segundo.

| local | muse | #res_ini | #res_fin | b.c. 0(p)(total) | b.c. 0(train) | b.c. 0(test) |
|-----------|------------|----------|----------|------------------|---------------|--------------|
| results0 | museData0 | 164 | 162 | 0.603659 | 0.612403 | 0.575758 |
| results1 | museData1 | 254 | 251 | 0.594488 | 0.635 | 0.431373 |
| results10 | museData10 | 137 | 133 | 0.49635 | 0.481132 | 0.481481 |
| results11 | museData11 | 155 | 150 | 0.567742 | 0.55 | 0.666667 |
| results12 | museData12 | 107 | 104 | 0.485981 | 0.481928 | 0.52381 |
| results13 | museData13 | 49 | 42 | 0.469388 | 0.484848 | 0.444444 |
| results14 | museData14 | 153 | 150 | 0.627451 | 0.625 | 0.6 |
| results15 | museData15 | 115 | 112 | 0.521739 | 0.539326 | 0.478261 |
| results16 | museData16 | 161 | 147 | 0.416149 | 0.393162 | 0.466667 |
| results17 | museData17 | 158 | 158 | 0.443038 | 0.468254 | 0.34375 |
| results18 | museData18 | 128 | 121 | 0.5 | 0.53125 | 0.4 |
| results19 | museData19 | 90 | 90 | 0.477778 | 0.486111 | 0.444444 |
| results4 | museData4 | 168 | 168 | 0.547619 | 0.559701 | 0.5 |
| results5 | museData5 | 223 | 221 | 0.515695 | 0.505682 | 0.555556 |
| results6 | museData6 | 104 | 103 | 0.480769 | 0.463415 | 0.571429 |
| results7 | museData7 | 119 | 119 | 0.302521 | 0.315789 | 0.25 |
| results8 | museData8 | 178 | 178 | 0.494382 | 0.471831 | 0.583333 |
| results9 | museData9 | 116 | 116 | 0.663793 | 0.641304 | 0.75 |

Tabla A.2: Balance de clases para las ventanas de 2,5 segundos.

| local | muse | #res_ini | #res_fin | b.c. 0(p)(total) | b.c. 0(train) | b.c. 0(test) |
|-----------|------------|----------|----------|------------------|---------------|--------------|
| results0 | museData0 | 164 | 163 | 0.603659 | 0.615385 | 0.575758 |
| results1 | museData1 | 254 | 252 | 0.594488 | 0.631841 | 0.431373 |
| results10 | museData10 | 137 | 135 | 0.49635 | 0.490741 | 0.481481 |
| results11 | museData11 | 155 | 155 | 0.567742 | 0.540323 | 0.677419 |
| results12 | museData12 | 107 | 106 | 0.485981 | 0.488095 | 0.5 |
| results13 | museData13 | 49 | 48 | 0.469388 | 0.447368 | 0.5 |
| results14 | museData14 | 153 | 152 | 0.627451 | 0.628099 | 0.612903 |
| results15 | museData15 | 115 | 114 | 0.521739 | 0.538462 | 0.478261 |
| results16 | museData16 | 161 | 160 | 0.416149 | 0.414062 | 0.4375 |
| results17 | museData17 | 158 | 158 | 0.443038 | 0.468254 | 0.34375 |
| results18 | museData18 | 128 | 125 | 0.5 | 0.52 | 0.4 |
| results19 | museData19 | 90 | 90 | 0.477778 | 0.486111 | 0.444444 |
| results4 | museData4 | 168 | 168 | 0.547619 | 0.559701 | 0.5 |
| results5 | museData5 | 223 | 222 | 0.515695 | 0.502825 | 0.555556 |
| results6 | museData6 | 104 | 103 | 0.480769 | 0.463415 | 0.571429 |
| results7 | museData7 | 119 | 119 | 0.302521 | 0.315789 | 0.25 |
| results8 | museData8 | 178 | 178 | 0.494382 | 0.471831 | 0.583333 |
| results9 | museData9 | 116 | 116 | 0.663793 | 0.641304 | 0.75 |

Tabla A.3: Balance de clases para las ventanas de 5 segundos.

| local | muse | #res_ini | #res_fin | b.c. 0(p)(total) | b.c. 0(train) | b.c. 0(test) |
|-----------|------------|----------|----------|------------------|---------------|--------------|
| results0 | museData0 | 164 | 164 | 0.603659 | 0.610687 | 0.575758 |
| results1 | museData1 | 254 | 254 | 0.594488 | 0.635468 | 0.431373 |
| results10 | museData10 | 137 | 136 | 0.49635 | 0.5 | 0.464286 |
| results11 | museData11 | 155 | 155 | 0.567742 | 0.540323 | 0.677419 |
| results12 | museData12 | 107 | 107 | 0.485981 | 0.482353 | 0.5 |
| results13 | museData13 | 49 | 49 | 0.469388 | 0.461538 | 0.5 |
| results14 | museData14 | 153 | 153 | 0.627451 | 0.631148 | 0.612903 |
| results15 | museData15 | 115 | 114 | 0.521739 | 0.538462 | 0.478261 |
| results16 | museData16 | 161 | 161 | 0.416149 | 0.414062 | 0.424242 |
| results17 | museData17 | 158 | 158 | 0.443038 | 0.468254 | 0.34375 |
| results18 | museData18 | 128 | 126 | 0.5 | 0.52 | 0.423077 |
| results19 | museData19 | 90 | 90 | 0.477778 | 0.486111 | 0.444444 |
| results4 | museData4 | 168 | 168 | 0.547619 | 0.559701 | 0.5 |
| results5 | museData5 | 223 | 223 | 0.515695 | 0.505618 | 0.555556 |
| results6 | museData6 | 104 | 104 | 0.480769 | 0.457831 | 0.571429 |
| results7 | museData7 | 119 | 119 | 0.302521 | 0.315789 | 0.25 |
| results8 | museData8 | 178 | 178 | 0.494382 | 0.471831 | 0.583333 |
| results9 | museData9 | 116 | 116 | 0.663793 | 0.641304 | 0.75 |

Tabla A.4: Balance de clases para las ventanas de 10 y 7,5 segundos.

Bibliografía

- [1] Chun Siong Soon et al. «Unconscious determinants of free decisions in the human brain». En: *Nature Neuroscience* 2008 11:5 11 (5 abr. de 2008), págs. 543-545. ISSN: 1546-1726. DOI: [10.1038/nn.2112](https://doi.org/10.1038/nn.2112). URL: <https://www.nature.com/articles/nn.2112> (Go back).
- [2] Peter Düring et al. «Comparison of Non-Invasive Individual Monitoring of the Training and Health of Athletes with Commercially Available Wearable Technologies». En: *Frontiers in Physiology* 7 (mar. de 2016). wearable, págs. 1-2. ISSN: 1664-042X. DOI: [10.3389/fphys.2016.00071](https://doi.org/10.3389/fphys.2016.00071) (Go back).
- [3] Javier Minguez. «Tecnología de Interfaz Cerebro-Computador». En: *Journal Name* (Year) (Go back).
- [4] Er Jasjeet Kaur y Patiala Er Amanpreet Kaur. *A Review on Analysis of EEG Signals*. ISBN: 9781467369114 (Go back).
- [5] *El conductismo en psicología: ¿cómo interactúa el individuo con su entorno?* <https://www.unir.net/revista/salud/conductismo-psicologia/> (Go back).
- [6] *Libre Albedrío - Concepto y abordaje en diferentes ámbitos — concepto.de*. <https://concepto.de/libre-albedrio/> (Go back).
- [7] Teresa Martín Blas y Ana Serrano Fernández. *Movimiento ondulatorio. Introducción*. Accessed: 2024-09-18. URL: <https://www2.montes.upm.es/dptos/digfa/cfisica/ondas/ondasintro.html> (Go back).
- [8] Roland Priemer. «Introductory Signal Processing». En: *Introductory Signal Processing* (nov. de 1990). DOI: [10.1142/0864](https://doi.org/10.1142/0864). URL: https://books.google.com/books/about/Introductory_Signal_Processing.html?hl=es&id=QBT7nP7zTLgC (Go back).
- [9] Priyanka A. Abhang, Bharti W. Gawali y Suresh C. Mehrotra. «Chapter 2 - Technological Basics of EEG Recording and Operation of Apparatus». En: *Introduction to EEG- and Speech-Based Emotion Recognition*. Ed. por Priyanka A. Abhang, Bharti W. Gawali y Suresh C. Mehrotra. Academic Press, 2016, págs. 19-50. ISBN: 978-0-12-804490-2. DOI: <https://doi.org/10.1016/B978-0-12-804490-2.00002-6>.

- URL: <https://www.sciencedirect.com/science/article/pii/B9780128044902000026> (Go back).
- [10] Enrique Sanchez. *Tema IV: Series de Fourier*. Accessed: 2024-09-17. URL: https://enrique.sanchez.webs.uvigo.es/PDFs/ml114_TemaIV.pdf (Go back).
- [11] peter.schaldenbrand@siemens.com. *Digital Signal Processing: Sampling Rates, Bandwidth, Spectral Lines, and more*. Accessed: 2024-09-15. URL: <https://community.sw.siemens.com/s/article/digital-signal-processing-sampling-rates-bandwidth-spectral-lines-and-more> (Go back).
- [12] Claude E. Shannon. «Communication in the Presence of Noise». En: *Proceedings of the IRE* 37 (1949), pág. 11. URL: <https://api.semanticscholar.org/CorpusID:12037187> (Go back).
- [13] Omair Ali et al. *Improving the performance of EEG decoding using anchored-STFT in conjunction with gradient norm adversarial augmentation*. Nov. de 2020. DOI: [10.48550/arXiv.2011.14694](https://doi.org/10.48550/arXiv.2011.14694) (Go back).
- [14] daniele.patoner. *Time-Frequency analysis*. Accessed: 2024-09-18. URL: <https://wiki.cimec.unitn.it/tiki-index.php?page=Time-frequency+analysis> (Go back).
- [15] ¿Qué es la inteligencia artificial o IA? — Google Cloud — [cloud.google.com](https://cloud.google.com/learn/what-is-artificial-intelligence?hl=es-419). <https://cloud.google.com/learn/what-is-artificial-intelligence?hl=es-419> (Go back).
- [16] ¿Qué es el aprendizaje automático? Tipos y usos — Google Cloud — [cloud.google.com](https://cloud.google.com/learn/what-is-machine-learning?hl=es-419). <https://cloud.google.com/learn/what-is-machine-learning?hl=es-419> (Go back).
- [17] *What is Feature Extraction? Feature Extraction Techniques Explained* — [domino.ai](https://domino.ai/data-science-dictionary/feature-extraction). <https://domino.ai/data-science-dictionary/feature-extraction> (Go back).
- [18] German Federal Ministry of Education y Research under grant number 01IS14004 (project iPRODIGE). <https://tsfresh.readthedocs.io/en/latest/> (Go back).
- [19] Maximilian Christ et al. «Time Series Feature Extraction on basis of Scalable Hypothesis tests (tsfresh – A Python package)». En: *Neurocomputing* 307 (sep. de 2018), págs. 72-77. ISSN: 0925-2312. DOI: [10.1016/J.NEUCOM.2018.03.067](https://doi.org/10.1016/J.NEUCOM.2018.03.067) (Go back).
- [20] Jason Brownlee. *How to Choose a Feature Selection Method For Machine Learning* - [MachineLearningMastery.com](https://machinelearningmastery.com/feature-selection-with-real-and-categorical-data/) — [machinelearningmastery.com](https://machinelearningmastery.com/feature-selection-with-real-and-categorical-data/). <https://machinelearningmastery.com/feature-selection-with-real-and-categorical-data/> (Go back).

- [21] Andrzej Maćkiewicz y Waldemar Ratajczak. «Principal components analysis (PCA)». En: *Computers Geosciences* 19 (3 mar. de 1993), págs. 303-342. ISSN: 0098-3004. DOI: [10.1016/0098-3004\(93\)90090-R](https://doi.org/10.1016/0098-3004(93)90090-R) (Go back).
- [22] ¿Qué es la estadística univariada? <https://es.statisticseasily.com/glossario/what-is-univariate-statistics/> (Go back).
- [23] D. CARLOS MANTEROLA, N. VIVIANA PINEDA y GRUPO MINCIR. «El valor de "p" la "significación estadística": Aspectos generales y su valor en la práctica clínica». En: *Revista chilena de cirugía* 60 (1 2008), págs. 86-89. ISSN: 0718-4026. DOI: [10.4067/S0718-40262008000100018](https://doi.org/10.4067/S0718-40262008000100018). URL: http://www.scielo.cl/scielo.php?script=sci_arttext&pid=S0718-40262008000100018&lng=es&nrm=iso&tlng=es%20http://www.scielo.cl/scielo.php?script=sci_abstract&pid=S0718-40262008000100018&lng=es&nrm=iso&tlng=es (Go back).
- [24] *Feature Relevance*. https://tsfresh.readthedocs.io/en/latest/api/tsfresh.feature_selection.html (Go back).
- [25] Paula Rodó. *Niveles de significación*. <https://economipedia.com/definiciones/niveles-de-significacion.html> (Go back).
- [26] Chris Ding y Hanchuan Peng. «Peng, H.: Minimum Redundancy Feature Selection from Microarray Gene Expression Data. Journal of Bioinformatics and Computational Biology 3(2), 185-205». En: *Journal of bioinformatics and computational biology* 3 (mayo de 2005), págs. 185-205. DOI: [10.1142/S0219720005001004](https://doi.org/10.1142/S0219720005001004) (Go back).
- [27] Hanchuan Peng, Fuhui Long y Chris Ding. «Feature selection based on mutual information: criteria of max-dependency, max-relevance, and min-redundancy». En: *IEEE transactions on pattern analysis and machine intelligence* 27 (8 ago. de 2005), págs. 1226-1238. ISSN: 0162-8828. DOI: [10.1109/TPAMI.2005.159](https://doi.org/10.1109/TPAMI.2005.159). URL: <https://pubmed.ncbi.nlm.nih.gov/16119262/> (Go back).
- [28] Benjamin Auffarth, Maite López y Jesús Cerquides. «Comparison of redundancy and relevance measures for feature selection in tissue classification of CT images». En: *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)* 6171 LNAI (2010), págs. 248-262. ISSN: 03029743. DOI: [10.1007/978-3-642-14400-4_20](https://doi.org/10.1007/978-3-642-14400-4_20). URL: https://www.researchgate.net/publication/225143114_Comparison_of_Redundancy_and_Relevance_Measures_for_Feature_Selection_in_Tissue_Classification_of_CT_Images (Go back).
- [29] ¿Qué es un modelo de IA? — IBM — *ibm.com*. <https://www.ibm.com/es-es/topics/ai-model> (Go back).

- [30] *Clasificación con Árboles de Decisión: el algoritmo CART* — *codificandobits.com*. [Accessed 28-10-2024]. URL: <https://codificandobits.com/blog/clasificacion-arboles-decision-algoritmo-cart/> (Go back).
- [31] *Coeficiente de Gini en R (Índice Gini en R)* — *estadisticamente.com*. [Accessed 28-10-2024]. URL: <https://estadisticamente.com/coeficiente-gini-r/> (Go back).
- [32] Alfonso V. *Calcular la Ganancia de Información* — *linkedin.com*. [Accessed 28-10-2024]. URL: <https://www.linkedin.com/pulse/calcular-la-ganancia-de-informaci%C3%B3n-alfonso-villamizar-de-la-hoz-m8kye/> (Go back).
- [33] Mohamad. *MSE – Error Cuadrático Medio*. [Accessed 28-10-2024]. URL: <https://support.numxl.com/hc/es/articles/115001223423-MSE-Error-Cuadr%C3%A1tico-Medio> (Go back).
- [34] *¿Qué es el bagging?* — IBM — *ibm.com*. <https://www.ibm.com/mx-es/topics/bagging>. [Accessed 29-10-2024] (Go back).
- [35] *Introduction to Machine Learning Bootstrapping*. <https://carpentries-incubator.github.io/machine-learning-novice-python/07-bootstrapping/index.html>. [Accessed 29-10-2024] (Go back).
- [36] Rafay Qayyum. *Computational Complexity of Machine Learning Algorithms* — *rafayqayyum.medium.com*. <https://rafayqayyum.medium.com/computational-complexity-of-machine-learning-algorithms-254c275de84> (Go back).
- [37] *Introduction to Boosted Trees* & *xgboost 2.1.1 documentation* — *xgboost.readthedocs.io*. <https://xgboost.readthedocs.io/en/stable/tutorials/model.html>. [Accessed 29-10-2024] (Go back).
- [38] Jerome Friedman. «Greedy Function Approximation: A Gradient Boosting Machine». En: *The Annals of Statistics* 29 (nov. de 2000). DOI: 10.1214/aos/1013203451 (Go back).
- [39] *Support Vector Machine*. URL: [https://es.mathworks.com/discovery/support-vector-machine.html#:~:text=Support%20vector%20machine%20\(SVM\)%20es,reconocimiento%20de%20im%C3%A1genes%20y%20voz.](https://es.mathworks.com/discovery/support-vector-machine.html#:~:text=Support%20vector%20machine%20(SVM)%20es,reconocimiento%20de%20im%C3%A1genes%20y%20voz.) (Go back).
- [40] Mohammad Hossin y Md Nasir Sulaiman. «A review on evaluation metrics for data classification evaluations». En: *International journal of data mining & knowledge management process* 5.2 (2015), pág. 1 (Go back).
- [41] Scikit. *Classification metrics*. Accessed: 2024-10-18. URL: <https://scikit-learn.org/1.5/api/sklearn.metrics.html#classification-metrics> (Go back).

- [42] Yajing Si et al. «Different Decision-Making Responses Occupy Different Brain Networks for Information Processing: A Study Based on EEG and TMS». En: *Cerebral Cortex* 29.10 (dic. de 2018), págs. 4119-4129. ISSN: 1047-3211. DOI: [10.1093/cercor/bhy294](https://doi.org/10.1093/cercor/bhy294). eprint: <https://academic.oup.com/cercor/article-pdf/29/10/4119/29955334/bhy294.pdf>. URL: <https://doi.org/10.1093/cercor/bhy294> (Go back).
- [43] Yu-Hua Yeh, Joel Myerson y Leonard Green. «Delay discounting, cognitive ability, and personality: What matters?» En: (). DOI: [10.3758/s13423-020-01777-w](https://doi.org/10.3758/s13423-020-01777-w). URL: <https://doi.org/10.3758/s13423-020-01777-w> (Go back).
- [44] Daniel C. Krawczyk. «Social Cognition». En: *Reasoning: The Neuroscience of how we Think* (ene. de 2018), págs. 283-311. ISSN: 0962-8436. DOI: [10.1016/B978-0-12-809285-9.00012-0](https://doi.org/10.1016/B978-0-12-809285-9.00012-0) (Go back).
- [45] BENJAMIN LIBET et al. «TIME OF CONSCIOUS INTENTION TO ACT IN RELATION TO ONSET OF CEREBRAL ACTIVITY (READINESS-POTENTIAL): THE UNCONSCIOUS INITIATION OF A FREELY VOLUNTARY ACT». En: *Brain* 106.3 (sep. de 1983), págs. 623-642. ISSN: 0006-8950. DOI: [10.1093/brain/106.3.623](https://doi.org/10.1093/brain/106.3.623). eprint: <https://academic.oup.com/brain/article-pdf/106/3/623/758650/106-3-623.pdf>. URL: <https://doi.org/10.1093/brain/106.3.623> (Go back).
- [46] Chun Siong Soon. «The Unconscious Formation of Motor and Abstract Intentions». En: (sep. de 2017) (Go back).
- [47] Agustina Lombardi. «El experimento de Libet y sus replicaciones (de 1983 a 2013)». En: *Naturaleza y Libertad. Revista de Estudios Interdisciplinarios* 0 (8 ene. de 2017). ISSN: 2254-9668. DOI: [10.24310/NATyLIB.2017.v0i8.6287](https://doi.org/10.24310/NATyLIB.2017.v0i8.6287). URL: <https://revistas.uma.es/index.php/naturaleza-y-libertad/article/view/6287> (Go back).
- [48] Patrick Haggard y Martin Eimer. «On the relation between brain potentials and the awareness of voluntary movements». En: *Experimental Brain Research* 126 (1 1999), págs. 128-133. ISSN: 00144819. DOI: [10.1007/S002210050722/METRICS](https://doi.org/10.1007/S002210050722/METRICS). URL: <https://link.springer.com/article/10.1007/s002210050722> (Go back).
- [49] Judy Trevena y Jeff Miller. «Brain preparation before a voluntary action: Evidence against unconscious movement initiation». En: *Consciousness and Cognition* 19 (1 mar. de 2010), págs. 447-456. ISSN: 1053-8100. DOI: [10.1016/J.CONCOG.2009.08.006](https://doi.org/10.1016/J.CONCOG.2009.08.006) (Go back).

- [50] Simone Kühn y Marcel Brass. «Retrospective construction of the judgement of free choice». En: *Consciousness and Cognition* 18 (1 mar. de 2009), págs. 12-21. ISSN: 1053-8100. DOI: [10.1016/J.CONCOG.2008.09.007](https://doi.org/10.1016/J.CONCOG.2008.09.007) (Go back).
- [51] Matthias Schultze-Kraft et al. «The point of no return in vetoing self-initiated movements». En: *Proceedings of the National Academy of Sciences of the United States of America* 113 (4 ene. de 2016), págs. 1080-1085. ISSN: 10916490. DOI: [10.1073/PNAS.1513569112](https://doi.org/10.1073/PNAS.1513569112)/SUPPL_FILE/PNAS.1513569112.SAPP.PDF. URL: <https://www.pnas.org/doi/abs/10.1073/pnas.1513569112> (Go back).
- [52] Francisco M. Garcia-Moreno, Ana Álvarez-Muelas y Daniel Fernández Mérida. *Muse EEG Subconscious Decisions Dataset*. Year. DOI: [10.5281/zenodo.8429740](https://doi.org/10.5281/zenodo.8429740) (Go back).
- [53] Wenyi Xiao et al. «Enhanced network synchronization connectivity following transcranial direct current stimulation (tDCS) in bipolar depression: effects on EEG oscillations and deep learning-based predictors of clinical remission». En: *medRxiv* (abr. de 2024), pág. 2024.04.19.24306029. DOI: [10.1101/2024.04.19.24306029](https://doi.org/10.1101/2024.04.19.24306029). URL: <https://www.medrxiv.org/content/10.1101/2024.04.19.24306029v1%20https://www.medrxiv.org/content/10.1101/2024.04.19.24306029v1.abstract> (Go back).
- [54] ¿Qué es la metodología ágil? — *redhat.com*. <https://www.redhat.com/es/topics/devops/what-is-agile-methodology> (Go back).
- [55] About releases - *GitHub Docs* — *docs.github.com*. <https://docs.github.com/en/repositories/releasing-projects-on-github/about-releases> (Go back).
- [56] *El modelo en cascada: desarrollo secuencial de software* — *ionos.es*. <https://www.ionos.es/digitalguide/paginas-web/desarrollo-web/el-modelo-en-cascada/> (Go back).
- [57] *Sueldos para el puesto de Ingeniero De Aprendizaje Automatico en España*. https://www.glassdoor.es/Sueldos/ingeniero-de-aprendizaje-automatico-sueldo-SRCH_K00,35.htm (Go back).
- [58] *Machine learning engineer: ¿cuánto gana?* — *Deusto Formación* — *deustoformacion.com*. <https://www.deustoformacion.com/cursos/programacion-tecnologia/curso-machine-learning/sueldo> (Go back).
- [59] ¿Cómo funciona la amortización de tus equipos informáticos? — *fleet.co*. <https://fleet.co/es/blog/amortizacion-ordenadores> (Go back).

- [60] Agencia Tributaria. *Agencia Tributaria: 3.5.4 Tabla de amortización simplificada* — *sede.agenciatributaria.gob.es*. https://sede.agenciatributaria.gob.es/Sede/ayuda/manuales-videos-folletos/manuales-practicos/folleto-actividades-economicas/3-impuesto-sobre-renta-personas-fisicas/3_5-estimacion-directa-simplificada/3_5_4-tabla-amortizacion-simplificada.html (Go back).
- [61] MathWorks. *Notch Filter*. Accessed: 2024-09-04. URL: <https://es.mathworks.com/discovery/notch-filter.html> (Go back).
- [62] Mind Monitor. *Manual técnico*. Accessed: 2024-09-13. URL: https://mind-monitor.com/Technical_Manual.php (Go back).
- [63] Learthgz. *What does epoch mean in EEG?* Accessed: 2024-09-09. URL: <https://dsp.stackexchange.com/questions/41135/what-does-epoch-mean-in-eeeg> (Go back).
- [64] *tsfresh.feature_extraction.extraction module*. https://tsfresh.readthedocs.io/en/latest/api/tsfresh.feature_extraction.html#tsfresh.feature_extraction.extraction.extract_features (Go back).
- [65] Abeer Al-Nafjan. «Feature selection of EEG signals in neuromarketing». En: *PeerJ Computer Science* 8 (2022), e944. ISSN: 23765992. DOI: 10.7717/PEERJ-CS.944/SUPP-1. URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC9138093/> (Go back).
- [66] smazzanti. *mrmmr/mrmmr/pandas.py at main · smazzanti/mrmmr* — *github.com*. <https://github.com/smazzanti/mrmmr/blob/main/mrmmr/pandas.py#L95> (Go back).
- [67] Shaun Turney. *Pearson Correlation Coefficient (r) — Guide & Examples* — *scribbr.com*. <https://www.scribbr.com/statistics/pearson-correlation-coefficient/> (Go back).
- [68] *F-Test* — *statisticshowto.com*. <https://www.statisticshowto.com/probability-and-statistics/hypothesis-testing/f-test/> (Go back).
- [69] IBM. *Prueba de Kolmogorov-Smirnov para una muestra* — *ibm.com*. <https://www.ibm.com/docs/es/spss-statistics/saas?topic=tests-one-sample-kolmogorov-smirnov-test> (Go back).
- [70] X. Liao et al. «Combining spatial filters for the classification of single-trial EEG in a finger movement task». En: *IEEE Transactions on Biomedical Engineering* 54 (5 mayo de 2007), págs. 821-831. ISSN: 00189294. DOI: 10.1109/TBME.2006.889206 (Go back).

-
- [71] Qian Cai et al. «Multilinear Discriminative Spatial Patterns for Movement-Related Cortical Potential Based on EEG Classification with Tensor Representation». En: *Computational Intelligence and Neuroscience* 2021 (2021), pág. 6634672. ISSN: 16875273. DOI: [10.1155/2021/6634672](https://doi.org/10.1155/2021/6634672). URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC8175166/> ([Go back](#)).
- [72] Chenxi Huang, Yutian Xiao y Gaowei Xu. «Predicting Human Intention-Behavior Through EEG Signal Analysis Using Multi-Scale CNN». En: *IEEE/ACM transactions on computational biology and bioinformatics* 18 (5 2021), págs. 1722-1729. ISSN: 1557-9964. DOI: [10.1109/TCBB.2020.3039834](https://doi.org/10.1109/TCBB.2020.3039834). URL: <https://pubmed.ncbi.nlm.nih.gov/33226953/> ([Go back](#)).
- [73] Keiron O'Shea y Ryan Nash. «An Introduction to Convolutional Neural Networks». En: *International Journal for Research in Applied Science and Engineering Technology* 10 (12 nov. de 2015), págs. 943-947. DOI: [10.22214/ijraset.2022.47789](https://doi.org/10.22214/ijraset.2022.47789). URL: <https://arxiv.org/abs/1511.08458v2> ([Go back](#)).